Mostrar código

Análisis de Riesgo de Diabetes e Insights de Salud Pública

EE.UU. BRFSS 2023 • SQL • Clustering • Dashboard en Streamlit • Contexto Latinoamericano

Autor: Emilio Nahuel Pattini
Fecha: Abril 2025
Objetivo: Analizar factores de riesgo de diabetes utilizando datos del BRFSS 2023 (EE.UU.), construir modelos predictivos, realizar clustering para segmentación poblacional y contextualizar hallazgos con tendencias y proyecciones de América Latina (datos de OPS e IDF).

Descripción del Proyecto

Este proyecto busca:

- Realizar análisis exploratorio de datos (EDA) sobre indicadores de diabetes del BRFSS 2023.
- Identificar factores de riesgo clave y correlaciones.
- Construir un modelo de clasificación para predecir riesgo de diabetes/pre-diabetes.
- Aplicar clustering para segmentar poblaciones según perfiles de riesgo.
- Enriquecer el análisis con datos regionales de América Latina (tendencias de prevalencia, carga, mortalidad, brechas de tratamiento).
- Proporcionar recomendaciones e insights de salud pública, especialmente relevantes para Argentina y América Latina.

Conjuntos de Datos

1. **Dataset Principal**
    - Fuente: CDC BRFSS 2023 (versión depurada de Kaggle)
    - Archivo: `diabetes_012_health_indicators_BRFSS2023.csv`
    - Filas: ~261,589
    - Variable objetivo: Diabetes_012 (0 = sin diabetes, 1 = pre-diabetes, 2 = diabetes)
    - Variables clave: IMC, Hipertensión, Salud General, Actividad Física, Edad, Ingreso, etc.
2. **Datasets de Contexto Latam**

- Atlas de Diabetes IDF – Proyecciones Sudamérica & Centroamérica (2000–2050)
  Archivo: `idf_south_central_america_formatted.csv`
- OPS Prevalencia y Cobertura de Tratamiento (1990–2022)
  Archivo: `paho_prevalence_trends.csv`
- OPS Carga de Diabetes 2019 (por subregión)
  Archivo: `paho_burden_2019.csv`
- OPS Muertes por País (2019)
  Archivo: `paho_level_by_country.csv`
- OPS Resumen – Brecha de Tratamiento (1990–2022)
  Archivo: `paho_diabetes_in_the_americas_summary_of_estimates.csv`

Objetivos

Objetivos Principales

- Comprender la prevalencia y factores de riesgo de diabetes en la población de EE.UU. (datos 2023).
- Construir y evaluar un modelo predictivo para clasificación de riesgo de diabetes.
- Identificar segmentos poblacionales con perfiles de riesgo similares mediante clustering.
- Comparar patrones de EE.UU. con tendencias y proyecciones futuras de América Latina.

Metas Técnicas

- Demostrar uso avanzado de SQL (DuckDB) para preparación y agregación de datos.
- Realizar EDA completo con visualizaciones interactivas (Plotly).
- Aplicar aprendizaje supervisado (clasificación) y no supervisado (clustering).
- Construir un dashboard interactivo (Streamlit) para exploración e insights.

Tabla de Contenidos

- 1. Preparación y Limpieza de Datos
  - 1.1 Preparación de Datos
  - 1.2 Limpieza Inicial de Datos
  - 1.3 Limpieza Final y Estandarización
  - 1.4 Conversión Final a Numérico
- 2. Análisis Exploratorio de Datos (EDA)
  - 2.1 Análisis Visual
  - 2.2 Insights y Conclusiones
- 3. Ingeniería de Características y SQL Avanzado
  - 3.1 Creación de Tabla de Trabajo
  - 3.2 Ingeniería de Características
  - 3.3 Exploración de Características
  - 3.4 Resumen de Ingeniería

    - 3.5 Creación de Tabla Final
- 4. Modelado Predictivo
    - 4.1 Enfoque Multiclase
    - 4.2 Clasificación Binaria
        - 4.2.1 Preparación de Datos
        - 4.2.2 Resultados
        - 4.2.3 Comparación de Modelos
        - 4.2.4 Importancia de Características
        - 4.2.5 Demostración del Modelo
- 5. Clustering y Segmentación Poblacional
    - 5.1 Número de Clusters
    - 5.2 Análisis de Clusters
    - 5.3 Perfiles e Interpretación
- 6. Contexto Latam y Comparaciones
    - 6.1 Indicadores Clave
    - 6.2 Comparación EE.UU. vs Latam
    - 6.3 Implicaciones
- 7. Conclusiones y Recomendaciones
    - 7.1 Resumen del Proyecto
    - 7.2 Hallazgos Clave
    - 7.3 Recomendaciones
    - 7.4 Limitaciones y Futuro
- 8. Dashboard en Streamlit
    - 8.1 Dashboard Interactivo
    - 8.2 Capturas

1. Preparación y Limpieza de Datos

1.1. Preparación de Datos

```
Table 'cdc' loaded.
Table 'idf' loaded.
Table 'paho_prevalence' loaded.
Table 'paho_burden' loaded.
Table 'paho_deaths_country' loaded.
Table 'paho_summary' loaded.

=== CDC ===
Rows: 261,589

Columns:
             column_name column_type
0           Diabetes_012      DOUBLE
1          KidneyDisease      DOUBLE
2                 HighBP      DOUBLE
3               HighChol      DOUBLE
4              CholCheck      DOUBLE
5                 Asthma      DOUBLE
6                   COPD      DOUBLE
7                    BMI      DOUBLE
8                 Smoker      DOUBLE
9                 Stroke      DOUBLE
10  HeartDiseaseorAttack      DOUBLE
11          PhysActivity      DOUBLE
12     HvyAlcoholConsump      DOUBLE
13         AnyHealthcare      DOUBLE
14           NoDocbcCost      DOUBLE
15               GenHlth      DOUBLE
16              MentHlth      DOUBLE
17              PhysHlth      DOUBLE
18              DiffWalk      DOUBLE
19                   Sex      DOUBLE
20              AgeGroup      DOUBLE
21             Education      DOUBLE
22                Income      DOUBLE

First 3 rows:
   Diabetes_012  KidneyDisease  HighBP  HighChol  CholCheck  Asthma  COPD  \
0           0.0            2.0     1.0       1.0        1.0     1.0   2.0
1           2.0            2.0     1.0       0.0        1.0     2.0   2.0
2           0.0            2.0     1.0       1.0        1.0     2.0   2.0

    BMI  Smoker  Stroke  HeartDiseaseorAttack  PhysActivity  \
0  22.0     1.0     0.0                   0.0           1.0
1  26.0     0.0     0.0                   0.0           1.0
2  30.0     0.0     0.0                   0.0           1.0

   HvyAlcoholConsump  AnyHealthcare  NoDocbcCost  GenHlth  MentHlth  PhysHlth  \
0                0.0            1.0          1.0      4.0       2.0       6.0
1                0.0            1.0          0.0      4.0       0.0       0.0
2                0.0            1.0          0.0      3.0       3.0       2.0

   DiffWalk  Sex  AgeGroup  Education  Income
0       1.0  0.0      13.0        4.0     2.0
1       1.0  0.0      12.0        5.0     7.0
2       0.0  0.0       9.0        5.0     7.0

=== IDF ===
Rows: 88
```

```
Columns:
  column_name column_type
0    Category     VARCHAR
1      Metric     VARCHAR
2        Year      BIGINT
3       Value      DOUBLE

First 3 rows:
                       Category  \
0  Diabetes estimates (20-79 y)
1  Diabetes estimates (20-79 y)
2  Diabetes estimates (20-79 y)

                                                Metric  Year   Value
0                     People with diabetes, in 1,000s  2000  8553.3
1         Age-standardised prevalence of diabetes, %  2000     3.7
2  Proportion of people with undiagnosed diabetes, %  2000     NaN

=== PAHO_PREVALENCE ===
Rows: 180

Columns:
         column_name column_type
0      Location Code     VARCHAR
1   Location Name En     VARCHAR
2  Indicator Name En     VARCHAR
3       Age Group En     VARCHAR
4             Sex En     VARCHAR
5               Year      BIGINT
6              Value     VARCHAR
7          Value Low     VARCHAR
8         Value High     VARCHAR

First 3 rows:
  Location Code        Location Name En  \
0           AMR  Region of the Americas
1           AMR  Region of the Americas
2           AMR  Region of the Americas

                                   Indicator Name En Age Group En      Sex En  \
0  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes
1  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes
2  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes

   Year   Value Value Low Value High
0  1990  42.47%    38.20%     46.90%
1  1995  44.62%    41.00%     48.20%
2  2000  46.60%    43.80%     49.50%

=== PAHO_BURDEN ===
Rows: 120

Columns:
        column_name column_type
0              Iso3     VARCHAR
1     Location Name     VARCHAR
2   AMRO subregions     VARCHAR
3     Causename Eng     VARCHAR
4              Year      BIGINT
5               Sex     VARCHAR
```

```
6         Age group     VARCHAR
7   Measure Name En     VARCHAR
8    Metric Name En     VARCHAR
9             Value     VARCHAR
10        Value Low     VARCHAR
11         Value Up     VARCHAR

First 3 rows:
   Iso3           Location Name         AMRO subregions  \
0  AMRO  Region of the Americas  Region of the Americas
1  AMRO  Region of the Americas  Region of the Americas
2  AMRO  Region of the Americas  Region of the Americas

                                       Causename Eng  Year         Sex  \
0  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes
1  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes
2  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes

          Age group                         Measure Name En Metric Name En  \
0  Age-standardized                                  Deaths           Rate
1  Age-standardized  Disability-Adjusted Life Years (DALYs)           Rate
2  Age-standardized      Years Lived with Disability (YLDs)           Rate

      Value Value Low  Value Up
0     19.64     17.26     22.02
1  1,119.49    866.64  1,423.70
2    604.86     408.1    847.76

=== PAHO_DEATHS_COUNTRY ===
Rows: 35

Columns:
              column_name column_type
0                    Iso3     VARCHAR
1       Quintiles classes     VARCHAR
2           Causename Eng     VARCHAR
3           Location Name     VARCHAR
4         Measure Name En     VARCHAR
5                    Year      BIGINT
6    Latitude (generated)      DOUBLE
7   Longitude (generated)      DOUBLE
8               Value Low      DOUBLE
9                Value Up      DOUBLE
10                  Value      DOUBLE

First 3 rows:
  Iso3      Quintiles classes  \
0  VEN  Quintile 3: 40 to 60%
1  VCT  Quintile 3: 40 to 60%
2  USA  Quintile 1:  0 to 20%

                                       Causename Eng  \
0  Diabetes mellitus (excluding CKD due to Diabetes)
1  Diabetes mellitus (excluding CKD due to Diabetes)
2  Diabetes mellitus (excluding CKD due to Diabetes)

                       Location Name Measure Name En  Year  \
0  Venezuela, Bolivarian Republic of          Deaths  2019
1   Saint Vincent and the Grenadines          Deaths  2019
2           United States of America          Deaths  2019
```

```
   Latitude (generated)  Longitude (generated)  Value Low   Value Up  \
0                6.9830               -64.5880   30.33924  49.751212
1               13.2528               -61.1949   35.87554  50.156859
2               40.0792               -98.8164    8.34613   9.646632

       Value
0  39.291483
1  42.725138
2   9.115689

=== PAHO_SUMMARY ===
Rows: 66

Columns:
          column_name column_type
0  Year of Year dated      BIGINT
1   Indicator Name En     VARCHAR
2    % of Total Value     VARCHAR

First 3 rows:
   Year of Year dated                                  Indicator Name En  \
0                1990  Number of people aged 30+ years with diabetes ...
1                1991  Number of people aged 30+ years with diabetes ...
2                1992  Number of people aged 30+ years with diabetes ...

  % of Total Value
0        42.36717%
1        42.77484%
2        43.18176%

Diabetes_012 (CDC): Distribution
   Diabetes_012   count  percentage
0           0.0  216762       82.86
1           1.0    6581        2.52
2           2.0   38246       14.62
```

1.2. Limpieza Inicial de Datos

Realizaré lo siguiente:

- Convertir cadenas de porcentajes a valores float
- Verificar valores faltantes
- Estandarizar nombres de columnas (minúsculas, sin espacios)
- Crear versiones depuradas de las tablas si es necesario

```
Example after cleaning (PAHO Prevalence):
                                   Indicator Name En  Year  Value Value Low  \
0  Diabetes treatment coverage (current use of gl...  2019  56.28      53.2
1  Diabetes treatment coverage (current use of gl...  2022  57.71      53.3
2  Diabetes treatment coverage (current use of gl...  2019  56.72      52.2
3  Diabetes treatment coverage (current use of gl...  2022  57.83      51.5
4  Diabetes treatment coverage (current use of gl...  2019  55.89      51.2
5  Diabetes treatment coverage (current use of gl...  2022  57.65      50.9
6  Diabetes treatment coverage (current use of gl...  2019  57.57      54.4
7  Diabetes treatment coverage (current use of gl...  2022   59.3      54.9
8  Diabetes treatment coverage (current use of gl...  2019  58.13      53.6
9  Diabetes treatment coverage (current use of gl...  2022  59.51      53.1

  Value High
0       59.4
1       62.1
2       61.0
3       63.9
4       60.3
5       63.9
6       60.7
7       63.7
8       62.5
9       65.6

Missing values in CDC:
             column_name  missing_count
0                 HighBP            0.0
1                    Sex            0.0
2              Education            0.0
3   HeartDiseaseorAttack            0.0
4      HvyAlcoholConsump            0.0
5                 Asthma            0.0
6                 Stroke            0.0
7               PhysHlth            0.0
8          KidneyDisease            0.0
9                    BMI            0.0
10               GenHlth            0.0
11           NoDocbcCost            0.0
12              DiffWalk            0.0
13          Diabetes_012            0.0
14                Income            0.0
15                Smoker            0.0
16              HighChol            0.0
17             CholCheck            0.0
18                  COPD            0.0
19              MentHlth            0.0
20              AgeGroup            0.0
21          PhysActivity            0.0
22         AnyHealthcare            0.0

All looks clean and ready for EDA.
```

1.3. Limpieza Final de Datos y Estandarización

Aquí estandarizo los nombres de columnas (minúsculas, guiones bajos) en todas las tablas y convierto la columna de porcentajes restante en el resumen de la OPS.

```
Example after cleaning PAHO Summary:
   Year of Year dated                                Indicator Name En  \
0                2019  Number of people aged 30+ years with diabetes ...
1                2022  Number of people aged 30+ years with diabetes ...
2                2019  Number of people aged 30+ years with diabetes ...
3                2022  Number of people aged 30+ years with diabetes ...

  % of Total Value
0         57.56768
1         59.30143
2         42.43232
3         40.69857

Standardized columns in cdc
Standardized columns in idf
Standardized columns in paho_prevalence
Standardized columns in paho_burden
Standardized columns in paho_deaths_country
Standardized columns in paho_summary

CDC columns after standardization:
             column_name
0           diabetes_012
1          kidneydisease
2                 highbp
3               highchol
4              cholcheck
5                 asthma
6                   copd
7                    bmi
8                 smoker
9                 stroke
10  heartdiseaseorattack
11          physactivity
12     hvyalcoholconsump
13         anyhealthcare
14           nodocbccost
15               genhlth
16              menthlth
17              physhlth
18              diffwalk
19                   sex
20              agegroup
21             education
22                income

All tables are now clean and standardized. Ready for EDA!
```

1.4. Conversión Final a Tipo Numérico

Aquí convertiré todas las columnas que deberían ser numéricas de VARCHAR a DOUBLE. Esto evita CASTs repetidos y asegura cálculos correctos.

```
Final numeric conversion check & fix...
  Converted paho_prevalence.value → DOUBLE
  Converted paho_prevalence.value_low → DOUBLE
  Converted paho_prevalence.value_high → DOUBLE
  Converted paho_burden.value → DOUBLE
  Converted paho_burden.value_low → DOUBLE
  Converted paho_burden.value_up → DOUBLE
  Converted paho_summary.percent_of_total_value → DOUBLE
  paho_deaths_country.value is already numeric (DOUBLE) - skipping
  paho_deaths_country.value_low is already numeric (DOUBLE) - skipping
  paho_deaths_country.value_up is already numeric (DOUBLE) - skipping

Final column types check:

PAHO_PREVALENCE:
         column_name column_type
0      location_code     VARCHAR
1   location_name_en     VARCHAR
2  indicator_name_en     VARCHAR
3       age_group_en     VARCHAR
4             sex_en     VARCHAR
5               year      BIGINT
6              value      DOUBLE
7          value_low      DOUBLE
8         value_high      DOUBLE

PAHO_BURDEN:
        column_name column_type
0              iso3     VARCHAR
1     location_name     VARCHAR
2   amro_subregions     VARCHAR
3     causename_eng     VARCHAR
4              year      BIGINT
5               sex     VARCHAR
6         age_group     VARCHAR
7   measure_name_en     VARCHAR
8    metric_name_en     VARCHAR
9             value      DOUBLE
10        value_low      DOUBLE
11         value_up      DOUBLE

PAHO_SUMMARY:
              column_name column_type
0      year_of_year_dated      BIGINT
1       indicator_name_en     VARCHAR
2  percent_of_total_value      DOUBLE

PAHO_DEATHS_COUNTRY:
            column_name column_type
0                  iso3     VARCHAR
1     quintiles_classes     VARCHAR
2         causename_eng     VARCHAR
3         location_name     VARCHAR
4       measure_name_en     VARCHAR
5                  year      BIGINT
6    latitude_generated      DOUBLE
7   longitude_generated      DOUBLE
8             value_low      DOUBLE
9              value_up      DOUBLE
10                value      DOUBLE
```

2. Análisis Exploratorio de Datos (EDA)

Exploraré:

- Distribución de la variable objetivo ('Diabetes_012')
- Principales factores demográficos y de riesgo de salud
- Relaciones entre variables y estado de diabetes
- Contexto inicial de América Latina (tendencias de prevalencia)

2.1. Análisis Visual

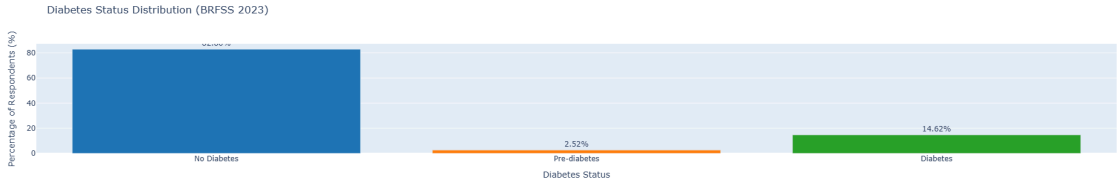

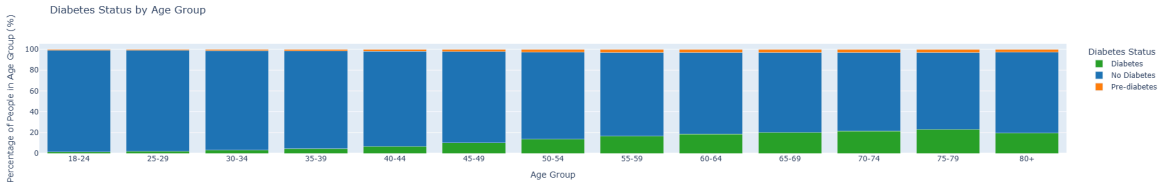

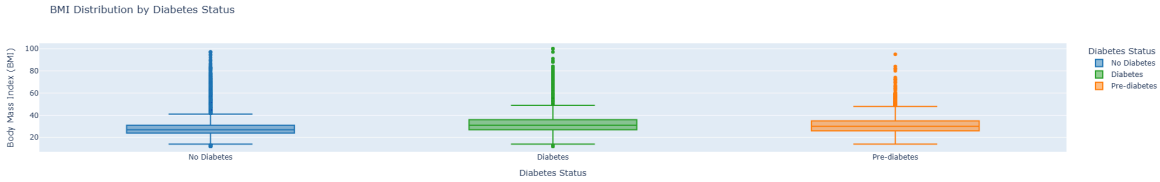


```
Diabetes Prevalence Trend (Americas 18+ years, age-standardized):
   year  avg_prevalence_percent
0  1990                    7.06
1  1995                    7.83
2  2000                    8.51
3  2005                    9.41
4  2010                   10.57
5  2015                   11.53
6  2019                   12.32
7  2020                   12.55
8  2021                   12.80
9  2022                   13.06
```

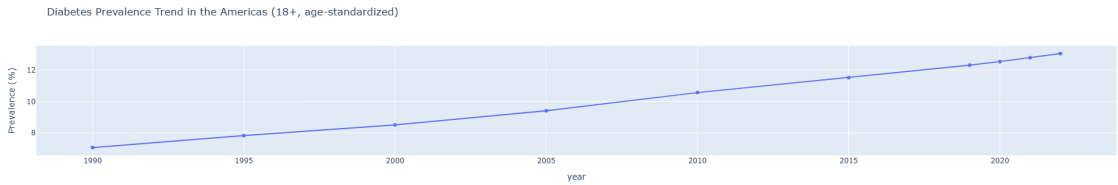

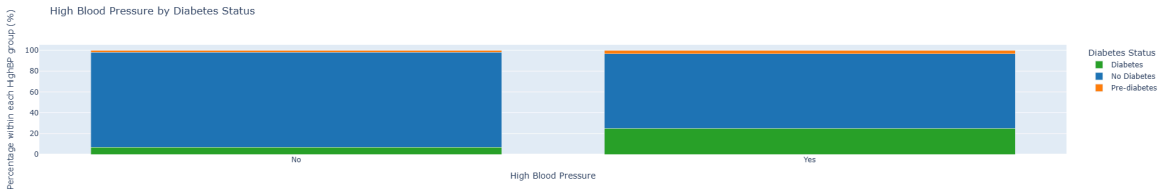

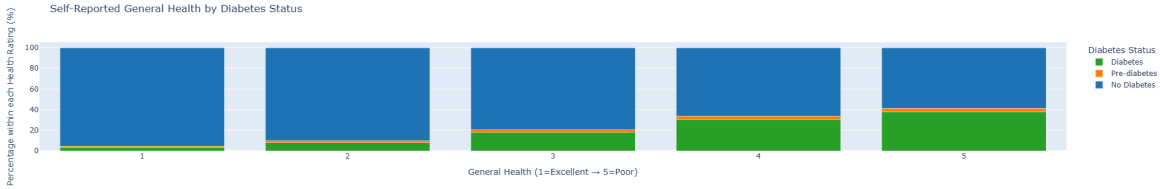

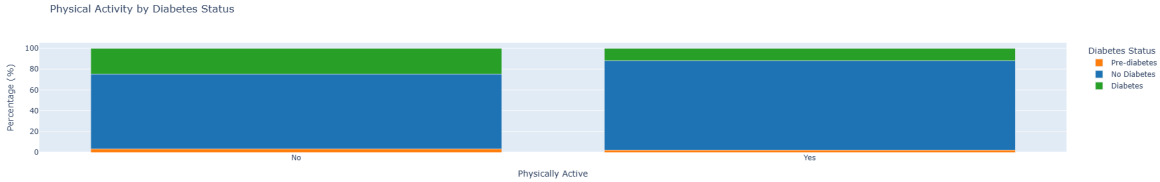

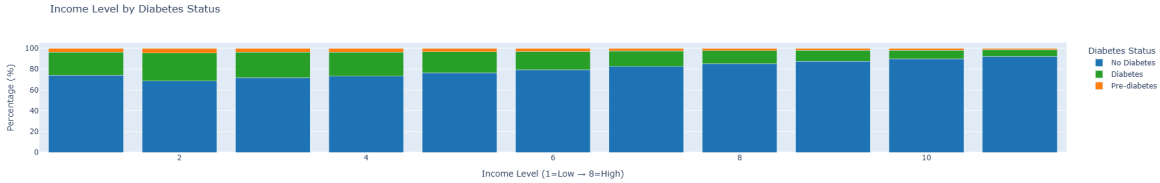

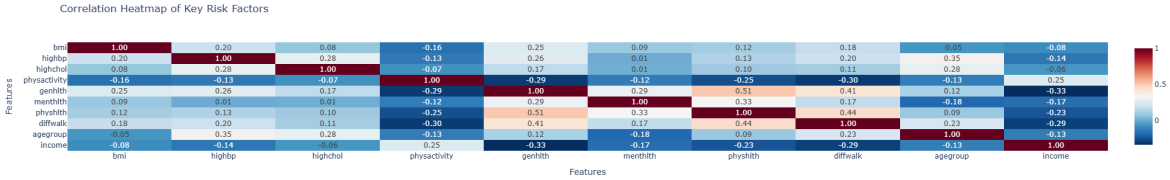

2.2. Principales Insights y Conclusiones

1. Distribución de la Variable Objetivo

- El dataset está fuertemente desbalanceado: **82.86%** de los encuestados no tienen diabetes, **14.62%** tienen diabetes y solo **2.52%** están en la categoría de pre-diabetes.
- Este desbalance es típico en datos de salud reales y deberá manejarse cuidadosamente durante el modelado (ej. usando pesos de clase o SMOTE).

2. Factores de Riesgo Más Fuertes

- **IMC**: Los individuos con diabetes (clase 2) muestran una mediana de IMC significativamente mayor. La obesidad aparece como uno de los factores más asociados.
- **Hipertensión**: Las personas con HighBP tienen una proporción mucho mayor de casos de diabetes. La relación es muy clara en el gráfico de barras apiladas.

- **Salud General**: Existe un fuerte gradiente: cuanto peor la salud general auto-reportada (mayor puntaje GenHlth), mayor el porcentaje de diabetes.
- **Edad**: La prevalencia de diabetes aumenta notablemente con la edad, especialmente después de los 50–55 años.
- **Actividad Física**: Los encuestados que reportan ser físicamente activos muestran una menor proporción de diabetes.

3. Patrones Socioeconómicos

- Niveles de ingreso más bajos están asociados con mayor prevalencia de diabetes, sugiriendo posibles vínculos con acceso a salud, nutrición y recursos de prevención.

4. Contexto de América Latina

- La prevalencia de diabetes en las Américas (estandarizada por edad, 18+) ha aumentado de ~7.1% en 1990 a ~13.1% en 2022.
- Las proyecciones de IDF para Sudamérica y Centroamérica muestran un aumento preocupante: de 10.1% en 2024 a un estimado **11.5% en 2050**, con un gran número de casos no diagnosticados (~30.4% en 2024).
- La carga de enfermedad (DALYs, muertes) es particularmente alta en subregiones como Centroamérica y el Caribe no latino.

5. Principales Conclusiones para la Salud Pública

- Los esfuerzos de prevención deben enfocarse en **factores de riesgo modificables**: control del IMC, manejo de la presión arterial y promoción de la actividad física.
- Intervenciones dirigidas a **adultos mayores (55+)** y **grupos de bajos ingresos** podrían tener gran impacto.
- La tendencia creciente en América Latina resalta la urgencia de políticas de prevención, tamizaje temprano y mejora en la cobertura de tratamiento (actualmente ~57–59% en la región).

Estos insights guiarán mis próximas fases de ingeniería de características, modelado y clustering, así como las recomendaciones finales para estrategias de salud pública en Argentina y América Latina.

---

3. Ingeniería de Características y SQL Avanzado

En esta sección usaré DuckDB para crear nuevas variables significativas y realizar transformaciones complejas.

Esto demostrará una preparación de datos eficiente a gran escala y conocimiento del dominio en factores de riesgo de diabetes.

Objetivos clave:

- Crear variables clínicamente relevantes (grupos de edad, categorías de IMC, puntajes de comorbilidad, etc.)
- Ingeniería de características de interacción y riesgo
- Enriquecer el dataset principal con contexto Latam mediante joins
- Preparar un conjunto de características limpio para modelado y clustering

3.1. Creación de una Tabla de Trabajo

```
Creating clean working table 'diabetes_features' for engineering...
Working table 'diabetes_features' created with 261589 rows
```

3.2. Ingeniería de Características

```
Starting feature engineering...
Feature engineering completed. New features added.

Sample of engineered features:
   diabetes_012        age_group_cat     bmi_category  comorbidity_count  \
0           0.0        Elderly (75+)           Normal                  7
1           2.0        Elderly (75+)       Overweight                  7
2           0.0       Senior (60-74)    Obese Class I                  8
3           0.0        Elderly (75+)    Obese Class I                  7
4           2.0        Elderly (75+)           Normal                  9
5           0.0  Middle Aged (45-59)  Obese Class III                  8
6           0.0       Senior (60-74)    Obese Class I                  6
7           0.0        Elderly (75+)           Normal                  6

   diabetes_risk_score                 age_bmi_risk_group  lifestyle_score
0                    4                      Standard Risk                2
1                    3                      Standard Risk                3
2                    3          High Risk: Senior + Obese                3
3                    5          High Risk: Senior + Obese                2
4                    2                      Standard Risk                2
5                    3  Moderate Risk: Middle-age + Obese                3
6                    2          High Risk: Senior + Obese                2
7                    1                      Standard Risk                1
```

3.3. Exploración de Características

Aquí analizaré cómo las nuevas características creadas se relacionan con el estado de diabetes.

```
=== Feature Exploration: New Variables vs Diabetes Status ===

1. Age Group Category vs Diabetes Prevalence:
         age_group_cat  total_count  diabetes_cases  diabetes_pct
0        Elderly (75+)        42191          8990.0         21.31
1       Senior (60-74)        88039         17700.0         20.10
2  Middle Aged (45-59)        64257          8824.0         13.73
3  Young Adult (18-44)        67102          2732.0          4.07

2. BMI Category vs Diabetes Prevalence:
      bmi_category  total_count  diabetes_cases  diabetes_pct
0      Underweight         3495           208.0          5.95
1           Normal        64682          4464.0          6.90
2       Overweight        93432         11392.0         12.19
3    Obese Class I        58433         11045.0         18.90
4   Obese Class II        24696          6079.0         24.62
5  Obese Class III        16851          5058.0         30.02

3. Average Comorbidities and Risk Score by Diabetes Status:
   diabetes_012  avg_comorbidities  avg_risk_score  avg_lifestyle_score
0           0.0               6.64            1.54                 2.35
1           1.0               7.08            2.53                 2.22
2           2.0               7.28            3.06                 2.13

4. Age + BMI Risk Groups vs Diabetes Prevalence:
                  age_bmi_risk_group  total_count  diabetes_pct
0          High Risk: Senior + Obese        46214         30.81
1  Moderate Risk: Middle-age + Obese        20456         23.27
2                      Standard Risk       194919          9.88
```

3.4. Resumen de Ingeniería de Características

Principales características creadas y su relación con la diabetes:

- **Grupo de Edad**: Fuerte correlación positiva con la edad. Los adultos mayores (75+) muestran una prevalencia de diabetes del 21.31%.
- **Categoría de IMC**: Predictor muy fuerte. La Obesidad Clase III tiene una tasa de diabetes del 30.02% vs 6.90% en peso normal.
- **Grupo de Riesgo Edad + IMC**: El grupo de mayor riesgo ("Alto Riesgo: Senior + Obeso") tiene una prevalencia de diabetes del 30.81%.
- **Conteo de Comorbilidades** y **Puntaje de Riesgo de Diabetes**: Ambos aumentan con el estado de diabetes.
- **Puntaje de Estilo de Vida**: Ligeramente más bajo en personas con diabetes.

Estas características capturan dimensiones clínicas y de comportamiento importantes y se usarán para modelado y clustering.

3.5. Creación de la Tabla Final para Modelado

Aquí creo una tabla final limpia `diabetes_model_ready` que contiene tanto características originales como creadas, lista para modelado y clustering.

```
Creating final modeling table...
Final modeling table 'diabetes_model_ready' created with 261589 rows

Columns ready for modeling:
['target', 'bmi', 'highbp', 'highchol', 'physactivity', 'genhlth', 'diffwalk', 'a
gegroup', 'income', 'sex', 'age_group_cat', 'bmi_category', 'comorbidity_count',
'diabetes_risk_score', 'age_bmi_risk_group', 'lifestyle_score', 'obese_class_ii
i', 'senior_or_elderly', 'has_metabolic_risk']
```

---

4. Modelado Predictivo

Construiré modelos de clasificación para predecir el riesgo de diabetes utilizando las características creadas en la sección anterior.

Objetivos

- Establecer un modelo base sólido
- Evaluar el rendimiento usando métricas apropiadas para datos de salud desbalanceados
- Identificar las características más importantes
- Comparar diferentes algoritmos (Regresión Logística vs Random Forest)

Usaré la tabla `diabetes_model_ready` creada en la sección anterior.

4.1. Enfoque Multiclase (Intento Inicial)

Primero intenté predecir tres clases separadas:

- 0 = Sin Diabetes
- 1 = Pre-diabetes
- 2 = Diabetes

Los modelos **tuvieron un rendimiento pobre**, especialmente en la clase minoritaria (pre-diabetes), principalmente debido al fuerte desbalance de clases (82.86% Sin Diabetes, 2.52% Pre-diabetes, 14.62% Diabetes).

Después de revisar los resultados, decidí simplificar el problema.

```
=== Preparing Data for Modeling ===

Shape after One-Hot Encoding: (261589, 26)
Categorical columns encoded: ['age_group_cat', 'bmi_category', 'age_bmi_risk_grou
p']
Training samples: 209,271
Test samples: 52,318
Class distribution in training set:
target
0.0    82.86
2.0    14.62
1.0     2.52
Name: proportion, dtype: float64
```

```
=== Training Multiple Models ===

Training Logistic Regression...

Logistic Regression Classification Report:
              precision    recall  f1-score   support

         0.0     0.9421    0.6324    0.7568     43353
         1.0     0.0386    0.2682    0.0674      1316
         2.0     0.3354    0.6168    0.4345      7649

    accuracy                         0.6210     52318
   macro avg     0.4387    0.5058    0.4196     52318
weighted avg     0.8307    0.6210    0.6923     52318

F1-score for Diabetes class (2): 0.4345
------------------------------------------------------------
Training Random Forest...

Random Forest Classification Report:
              precision    recall  f1-score   support

         0.0     0.8552    0.8912    0.8728     43353
         1.0     0.0255    0.0236    0.0245      1316
         2.0     0.3361    0.2603    0.2934      7649

    accuracy                         0.7771     52318
   macro avg     0.4056    0.3917    0.3969     52318
weighted avg     0.7584    0.7771    0.7668     52318

F1-score for Diabetes class (2): 0.2934
------------------------------------------------------------
Training XGBoost...

XGBoost Classification Report:
              precision    recall  f1-score   support

         0.0     0.8488    0.9783    0.9090     43353
         1.0     0.0000    0.0000    0.0000      1316
         2.0     0.5544    0.1700    0.2602      7649

    accuracy                         0.8355     52318
   macro avg     0.4677    0.3828    0.3897     52318
weighted avg     0.7844    0.8355    0.7912     52318

F1-score for Diabetes class (2): 0.2602
------------------------------------------------------------
```

4.2. Clasificación Binaria (Enfoque Final)

Dado el fuerte desbalance y el limitado poder predictivo en pre-diabetes, simplifiqué el problema a **clasificación binaria**:

- **Clase 0**: Sin Diabetes
- **Clase 1**: Pre-diabetes **o** Diabetes (cualquier riesgo de diabetes)

Este enfoque es más práctico para el tamizaje en el mundo real y produjo resultados significativamente mejores.

4.2.1. Preparación de Datos para Clasificación Binaria

Creé la variable objetivo binaria y apliqué One-Hot Encoding a las variables categóricas (`age_group_cat`, `bmi_category`, `age_bmi_risk_group`).

```
=== Binary Classification: No Diabetes vs Any Diabetes Risk ===

Training samples: 209,271
Test samples: 52,318
Positive class (Any diabetes risk) percentage: 17.14%
```

4.2.2. Resultados del Modelado

Regresión Logística

```
Training Logistic Regression (Binary)...
Logistic Regression Results:
              precision    recall  f1-score   support

           0     0.9329    0.7014    0.8007     43353
           1     0.3436    0.7561    0.4725      8965

    accuracy                         0.7107     52318
   macro avg     0.6383    0.7287    0.6366     52318
weighted avg     0.8319    0.7107    0.7445     52318
```

Random Forest

```
Training Random Forest (Binary)...
Random Forest Results:
              precision    recall  f1-score   support

           0     0.8591    0.8956    0.8770     43353
           1     0.3646    0.2898    0.3229      8965

    accuracy                         0.7918     52318
   macro avg     0.6119    0.5927    0.6000     52318
weighted avg     0.7744    0.7918    0.7820     52318
```

XGBoost

```
Training XGBoost (Binary)...
XGBoost Results:
              precision    recall  f1-score   support

           0     0.8517    0.9716    0.9077     43353
           1     0.5694    0.1816    0.2754      8965

    accuracy                         0.8362     52318
   macro avg     0.7105    0.5766    0.5915     52318
weighted avg     0.8033    0.8362    0.7993     52318
```

4.2.3. Comparación de Modelos

Comparación de modelos e insights:

- **Regresión Logística** logró el mejor **recall** (75.61%) para la clase positiva (cualquier riesgo de diabetes). Esto significa que es buena identificando personas en riesgo, incluso si a veces da falsas alarmas.
- **XGBoost** tuvo la mayor precisión global (83.62%) y mejor precisión puntual, pero perdió muchos casos verdaderos (recall bajo).
- **Random Forest** se desempeñó en un punto intermedio pero no fue el más fuerte en ninguna métrica clave.

Modelo elegido: Regresión Logística — porque en el tamizaje de salud pública es más importante detectar la mayor cantidad posible de personas en riesgo (alto recall) que ser muy preciso.

Estos resultados muestran que mis características creadas (especialmente IMC, edad, ingreso y conteo de comorbilidades) contienen señal predictiva útil para el riesgo de diabetes.

4.2.4. Análisis de Importancia de Características

Entender qué características contribuyen más a la predicción es crucial para la interpretabilidad y las recomendaciones de salud pública.

```
Top 15 Most Important Features (XGBoost):
                              feature  importance
10                diabetes_risk_score    0.368261
17  age_group_cat_Young Adult (18-44)    0.081003
13                  senior_or_elderly    0.068727
4                             genhlth    0.053791
24   age_bmi_risk_group_Standard Risk    0.049790
6                            agegroup    0.037466
14                 has_metabolic_risk    0.036997
20       bmi_category_Obese Class III    0.032434
1                              highbp    0.030059
3                        physactivity    0.022631
8                                 sex    0.021122
12                    obese_class_iii    0.021052
18         bmi_category_Obese Class I    0.018625
11                    lifestyle_score    0.016660
0                                 bmi    0.016236
```

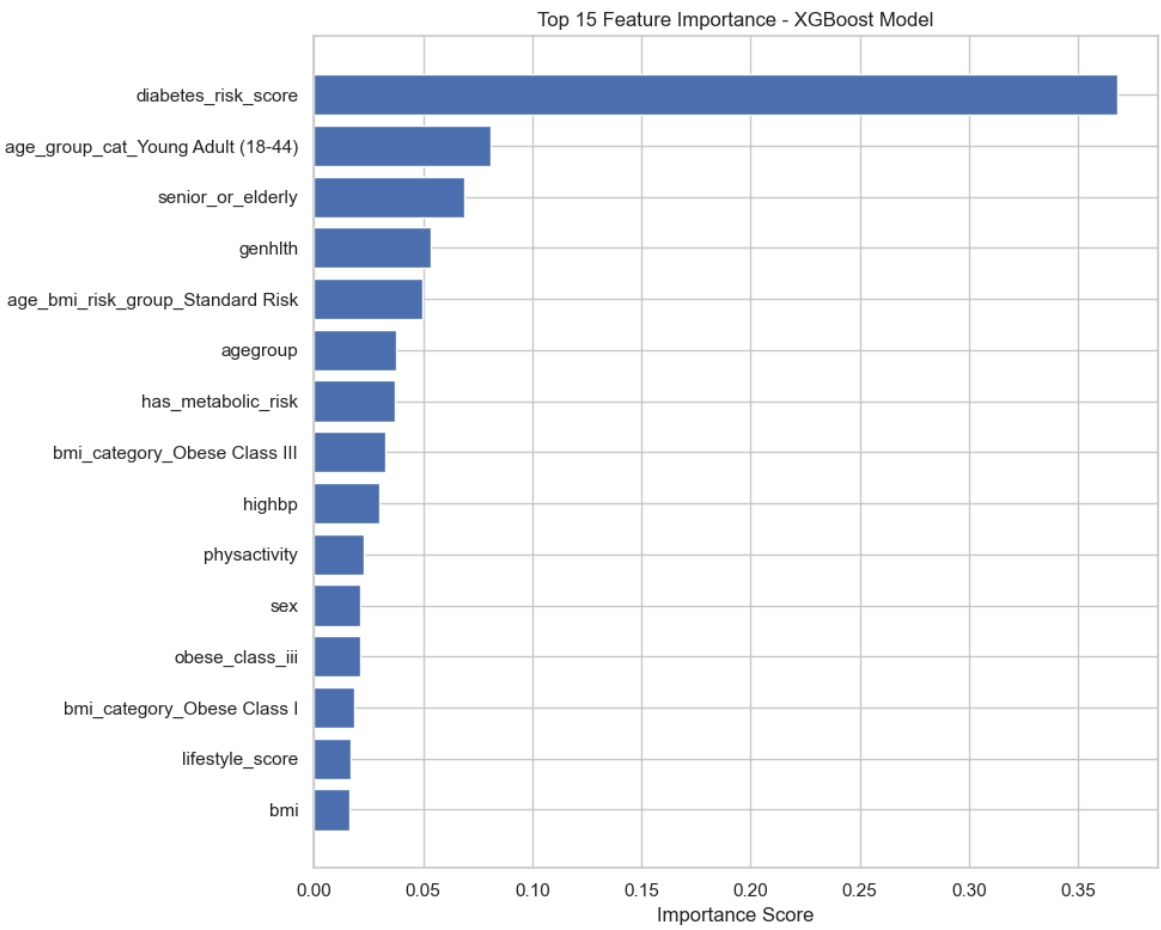

Top 5 características más importantes:

1. diabetes_risk_score (0.368) — Mi puntaje compuesto creado es el predictor más fuerte
2. Ser Adulto Joven (factor protector)
3. senior_or_elderly (edad 60+)
4. genhlth (salud general auto-reportada)
5. age_bmi_risk_group_Standard Risk

Esto confirma que la ingeniería de características agregó un valor significativo al modelo.

Aplicación Práctica

Este modelo puede usarse como Herramienta de Tamizaje de Riesgo de Diabetes:

- Los proveedores de salud pueden ingresar datos de pacientes para estimar el nivel de riesgo.
- Las organizaciones de salud pública podrían usarlo para priorizar campañas de tamizaje en grupos de alto riesgo (adultos mayores, personas obesas, poblaciones de bajos ingresos).
- Una versión web/app simplificada permitiría a individuos realizar una autoevaluación rápida.

Ejemplo de Uso:

Un paciente de 62 años con IMC 32, hipertensión y mala salud auto-reportada sería marcado como de alto riesgo, lo que impulsaría pruebas de glucosa tempranas e intervención en el estilo de vida.

4.2.5. Demostración del Modelo con Pacientes Ejemplo

Para ilustrar cómo podría usarse el modelo en la práctica, lo probé en cinco perfiles de pacientes realistas.

```
=== Model Demonstration with Example Patients ===

Using Logistic Regression (best recall model)

      age_group_cat  bmi_category  genhlth  highbp  physactivity Predicted Risk
Risk Probability (%)
Young Adult (18-44)        Normal        2       0             1       Low Risk
4.9
Young Adult (18-44)    Overweight        3       0             0       Low Risk
12.6
Middle Aged (45-59)    Overweight        3       1             1      High Risk
63.6
     Senior (60-74) Obese Class I        4       1             0      High Risk
87.1
     Senior (60-74) Obese Class I        4       1             0      High Risk
86.7
```

Interpretación:

El modelo se comporta lógicamente en la mayoría de los casos. Los adultos mayores con obesidad y mala salud general son clasificados correctamente como de alto riesgo (86–87% de probabilidad). Una persona de mediana edad con sobrepeso e hipertensión también es marcada como de alto riesgo.

Sin embargo, el modelo sigue siendo relativamente conservador con adultos jóvenes — incluso un adulto joven con sobrepeso y baja actividad física recibe solo un 12.6% de riesgo. Esto sugiere que la edad es un factor muy fuerte en el modelo actual. En un despliegue real, esto podría ajustarse dependiendo de si se prefiere mayor sensibilidad (detectar más casos) o mayor especificidad.

---

5. Clustering y Segmentación Poblacional

Aplicaré aprendizaje no supervisado (K-Means) para segmentar individuos en distintos grupos de riesgo basados en sus características.

Esto permite identificar subgrupos homogéneos y proporcionar recomendaciones de salud pública más específicas.

5.1. Elección del Número de Clusters

A continuación, uso el Método del Codo para determinar el número óptimo de clusters. El gráfico de inercia mostró una curva razonable alrededor de 4 clusters, que adopté por interpretabilidad.

```
=== Clustering Analysis ===
```

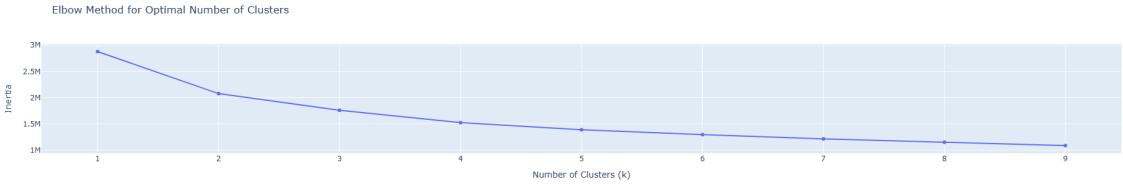


```
Cluster distribution:
cluster
0    95187
1    66017
2    37846
3    62539
Name: count, dtype: int64

Cluster Profiles (mean values):
           bmi  agegroup  genhlth  highbp  comorbidity_count  \
cluster
0        28.19      4.89     2.26    0.15               6.18
1        30.33      9.72     2.97    1.00               7.97
2        30.88      8.37     3.10    0.35               6.39
3        26.96     10.67     2.33    0.31               6.51

         diabetes_risk_score  lifestyle_score  target
cluster
0                       0.81             2.61    0.10
1                       3.33             2.16    0.64
2                       2.73             1.46    0.39
3                       1.08             2.55    0.26
```

5.2. Análisis de Clusters

Como se observa arriba, obtuve los siguientes cuatro clusters:

Distribución de Clusters:

- Cluster 0: 95,187 personas (36.4%)
- Cluster 1: 66,017 personas (25.2%)
- Cluster 2: 37,846 personas (14.5%)
- Cluster 3: 62,539 personas (23.9%)

5.3. Perfiles de Clusters e Interpretación

Identifiqué **4 segmentos poblacionales distintos** basados en sus características de salud.

Cluster	Número de Personas	Características Principales	Prevalencia de Diabetes (%)	Nivel de Riesgo	Recomendación
0	95,187	Adultos jóvenes, peso normal, buena salud general, pocas comorbilidades	10.0%	**Bajo Riesgo**	Prevención general
1	66,017	Adultos mayores, alto IMC, hipertensión, múltiples comorbilidades	64.0%	**Riesgo Muy Alto**	Tamizaje prioritario e intervención intensiva
2	37,846	Mediana edad a mayores, obesos, mala salud auto-reportada	39.0%	**Alto Riesgo**	Programas de estilo de vida dirigidos
3	62,539	Adultos mayores, IMC moderado, algunas comorbilidades	26.0%	**Riesgo Moderado**	Educación preventiva y monitoreo regular

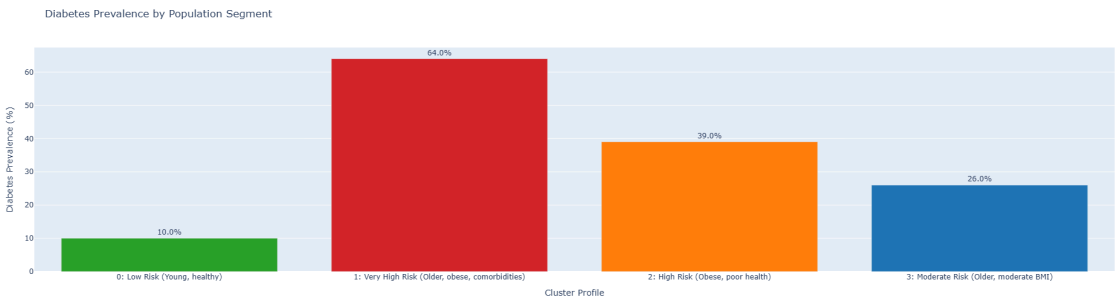

Insights Clave:

- **Cluster 1** es el grupo de mayor riesgo (64% prevalencia de diabetes). Consiste principalmente en adultos mayores con obesidad, hipertensión y múltiples comorbilidades. Este grupo debe ser priorizado para tamizaje agresivo e intervención.
- **Cluster 0** representa el segmento más saludable — principalmente jóvenes con buenos hábitos de vida y bajo riesgo.
- **Cluster 2** muestra que la obesidad combinada con mala salud auto-reportada incrementa significativamente el riesgo, incluso en mediana edad.
- La edad y el IMC continúan siendo factores dominantes en la segmentación de riesgo, reforzando hallazgos de las fases de EDA y modelado.

Estos clusters proporcionan insights accionables para la política de salud pública en Argentina y América Latina. Por ejemplo, los recursos podrían enfocarse en el Cluster 1 ("Adultos Mayores Obesos de Alto Riesgo") mediante programas comunitarios de tamizaje e intervenciones de estilo de vida.

---

6. Contexto Latam y Comparaciones

Para hacer el análisis más relevante para Argentina y América Latina, enriquecí los hallazgos del BRFSS de EE.UU. con datos regionales de la OPS y el Atlas de Diabetes de la IDF.

6.1. Indicadores Clave de Latam (Sudamérica y Centroamérica)

Indicador	Valor 2024	Proyección 2050	Observación
Prevalencia estandarizada por edad	10.1%	11.5%	Se espera aumento constante
Personas con diabetes	35.4 millones	51.5 millones	+45% de crecimiento proyectado
Diabetes no diagnosticada	~30.4%	-	Alta carga oculta
Cobertura de tratamiento (Américas, 30+ años)	~57–59%	-	Brecha significativa de tratamiento

Fuente: Atlas de Diabetes IDF & datos OPS

6.2. Comparación: Datos de EE.UU. vs Contexto Latam

- En el dataset BRFSS 2023 de EE.UU., la tasa observada de diabetes es **14.62%**.
- En Sudamérica y Centroamérica, la prevalencia actual es **10.1%** (2024), pero se proyecta que alcance **11.5% en 2050**.
- El cluster de mayor riesgo (Cluster 1) muestra una tasa de diabetes del **64%** — dramáticamente más alta que los promedios de EE.UU. y Latam. Esto sugiere que individuos con perfiles similares (mayor edad + obesidad + comorbilidades) representan un grupo crítico de alto riesgo en toda la región.
- La fuerte influencia de **IMC**, **edad** y **comorbilidades** en mi modelo coincide con factores de riesgo conocidos en América Latina, donde el aumento de la obesidad es un motor principal de la epidemia de diabetes.

6.3. Implicaciones para Argentina y América Latina

La combinación de los resultados de clustering y los datos regionales destaca la necesidad de **estrategias de prevención dirigidas**:

- Priorizar tamizaje e intervenciones de estilo de vida para adultos mayores con obesidad e hipertensión (similar al Cluster 1).

- Abordar la alta tasa de no diagnosticados (~30%) mediante programas comunitarios.
- Enfocarse en factores de riesgo modificables (control de IMC y actividad física), que mostraron fuerte poder predictivo en el modelo.

Estos hallazgos respaldan el desarrollo de políticas de salud pública localizadas en Argentina, donde la prevalencia de diabetes continúa en aumento.

---

7. Conclusiones y Recomendaciones

7.1. Resumen del Proyecto

Este proyecto analizó el riesgo de diabetes utilizando el dataset CDC BRFSS 2023 (~261k registros) combinado con contexto Latam de OPS e IDF.

El trabajo avanzó a través de:

- Preparación exhaustiva de datos y uso avanzado de SQL con DuckDB
- EDA completo con visualizaciones interactivas
- Ingeniería de características informada por el dominio (puntajes de riesgo, grupos edad+IMC, conteo de comorbilidades, etc.)
- Modelado predictivo (clasificación binaria)
- Segmentación poblacional usando clustering K-Means

7.2. Hallazgos Clave

- **Predictores más fuertes**: IMC, edad, salud general y comorbilidades fueron los factores más importantes.
- La prevalencia de diabetes aumenta significativamente con la edad, pasando de **4.07%** en adultos jóvenes (18–44) a **21.31%** en mayores (75+).
- El IMC emergió como uno de los predictores más fuertes, con prevalencia que sube de 6.9% en peso normal a **30.0%** en Obesidad Clase III.
- **Clustering** identificó **cuatro segmentos de riesgo**, con el grupo de mayor riesgo (adultos mayores con obesidad y comorbilidades) mostrando una tasa de diabetes del **64%**.
- **Rendimiento del modelo**: La clasificación binaria logró resultados razonables, con Regresión Logística ofreciendo el mejor recall (75.61%).
- **Contexto Latam**: La prevalencia creciente en Sudamérica y Centroamérica (10.1% en 2024 → 11.5% proyectado en 2050) y la alta tasa de no diagnosticados (~30%) hacen estos hallazgos muy relevantes.

7.3. Recomendaciones

Para Autoridades de Salud Pública (Argentina & Latam):

- Priorizar tamizaje dirigido para **Cluster 1** (adultos mayores con obesidad, hipertensión y múltiples comorbilidades).
- Implementar programas de prevención temprana enfocados en **manejo de peso** y **actividad física**.
- Abordar la brecha de tratamiento mejorando acceso a la atención en grupos de bajos ingresos.
- Usar herramientas de estratificación de riesgo como la desarrollada aquí para optimizar recursos limitados.

Para Individuos:

- Monitoreo regular de IMC, presión arterial y salud general para identificar riesgo temprano.
- Cambios de estilo de vida (más actividad física y peso saludable) tienen alto impacto potencial.

7.4. Limitaciones y Trabajo Futuro

- El modelo depende de datos auto-reportados, que pueden contener sesgos.
- La pre-diabetes sigue siendo difícil de predecir con este dataset.
- Mejoras futuras podrían incluir valores de laboratorio (HbA1c, glucosa en ayunas), historial familiar o datos geográficos más detallados.

Este proyecto demuestra habilidades de análisis de datos end-to-end — desde preparación intensiva en SQL hasta modelado e insights accionables de salud pública.

---

8. Dashboard Streamlit

🚀 Dashboard Interactivo

Puedes explorar la **versión totalmente interactiva** de este proyecto aquí:

🔗 **Abrir Diabetes Risk Analyzer →**

Capturas de Pantalla de la App

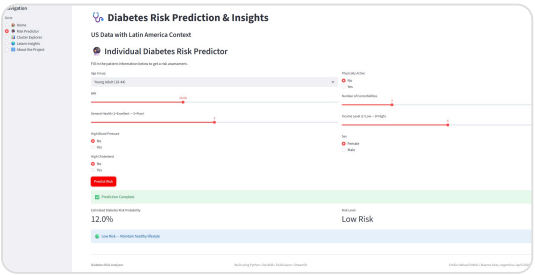

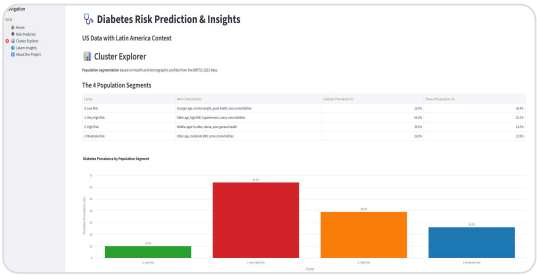

Qué puedes hacer en el dashboard:

- Calcular tu riesgo personal de diabetes usando el modelo entrenado
- Explorar los 4 segmentos poblacionales descubiertos mediante clustering
- Ver tendencias de diabetes y proyecciones al 2050 para Sudamérica y Centroamérica

Nota: El dashboard está desplegado en Streamlit Community Cloud y es totalmente interactivo.

¡Gracias por ver este proyecto!
No dudes en contactarme si tienes preguntas o comentarios.

```
✅ Successfully saved 'data/diabetes_model_ready.parquet'
Shape: (261589, 29)
Columns: ['diabetes_012', 'bmi', 'highbp', 'highchol', 'cholcheck', 'smoker', 'st
roke', 'heartdiseaseorattack', 'physactivity', 'hvyalcoholconsump', 'genhlth', 'm
enthlth', 'physhlth', 'diffwalk', 'sex', 'agegroup', 'education', 'income', 'kidn
eydisease', 'asthma', 'copd', 'anyhealthcare', 'nodocbccost', 'age_group_cat', 'b
mi_category', 'comorbidity_count', 'diabetes_risk_score', 'age_bmi_risk_group',
'lifestyle_score']

✅ Model saved successfully as 'models/logistic_regression_model.pkl'
Folder 'models' created if it didn't exist.

✅ Model columns saved as 'models/model_columns.json'
```