Mostra codice

Analisi del Rischio Diabete e Insights di Sanità Pubblica

USA BRFSS 2023 • SQL • Clustering • Dashboard Streamlit • Contesto Latinoamericano

Autore: Emilio Nahuel Pattini
Data: Aprile 2025
Obiettivo: Analizzare i fattori di rischio del diabete utilizzando i dati BRFSS 2023 (USA), costruire modelli predittivi, eseguire clustering per la segmentazione della popolazione e contestualizzare i risultati con tendenze e proiezioni dell'America Latina (dati PAHO e IDF).

Panoramica del Progetto

Questo progetto mira a:

- Eseguire analisi esplorativa dei dati (EDA) sugli indicatori di diabete del BRFSS 2023.
- Identificare i principali fattori di rischio e correlazioni.
- Costruire un modello di classificazione per prevedere il rischio di diabete/pre-diabete.
- Applicare clustering per segmentare le popolazioni in base ai profili di rischio.
- Arricchire l'analisi con dati regionali dell'America Latina (tendenze di prevalenza, carico, mortalità, gap di trattamento).
- Fornire raccomandazioni e approfondimenti di sanità pubblica, particolarmente rilevanti per Argentina e America Latina.

Dataset

1. **Dataset Principale**
   - Fonte: CDC BRFSS 2023 (versione pulita da Kaggle)
   - File: `diabetes_012_health_indicators_BRFSS2023.csv`
   - Righe: ~261,589
   - Variabile target: Diabetes_012 (0 = nessun diabete, 1 = pre-diabete, 2 = diabete)
   - Variabili chiave: BMI, Ipertensione, Salute Generale, Attività Fisica, Età, Reddito, ecc.
2. **Dataset di Contesto Latam**

- Atlante del Diabete IDF – Proiezioni Sud & Centro America (2000–2050)
  File: `idf_south_central_america_formatted.csv`
- PAHO Prevalenza e Copertura del Trattamento (1990–2022)
  File: `paho_prevalence_trends.csv`
- PAHO Carico del Diabete 2019 (per sottoregione)
  File: `paho_burden_2019.csv`
- PAHO Morti per Paese (2019)
  File: `paho_level_by_country.csv`
- PAHO Sintesi – Gap di Trattamento (1990–2022)
  File: `paho_diabetes_in_the_americas_summary_of_estimates.csv`

Obiettivi

Obiettivi Principali

- Comprendere la prevalenza e i fattori di rischio del diabete nella popolazione USA (dati 2023).
- Costruire e valutare un modello predittivo per la classificazione del rischio di diabete.
- Identificare segmenti di popolazione con profili di rischio simili tramite clustering.
- Confrontare i pattern USA con le tendenze e proiezioni future dell'America Latina.

Obiettivi Tecnici

- Dimostrare uso avanzato di SQL (DuckDB) per preparazione e aggregazione dei dati.
- Eseguire EDA completo con visualizzazioni interattive (Plotly).
- Applicare machine learning supervisionato (classificazione) e non supervisionato (clustering).
- Costruire un dashboard interattivo (Streamlit) per esplorazione e approfondimenti.

Indice

- 1. Preparazione e Pulizia dei Dati
  - 1.1 Preparazione dei Dati
  - 1.2 Pulizia Iniziale dei Dati
  - 1.3 Pulizia Finale e Standardizzazione
  - 1.4 Conversione Finale a Tipo Numerico
- 2. Analisi Esplorativa dei Dati (EDA)
  - 2.1 Analisi Visiva
  - 2.2 Principali Insights e Conclusioni
- 3. Feature Engineering e SQL Avanzato
  - 3.1 Creazione di una Tabella di Lavoro
  - 3.2 Feature Engineering
  - 3.3 Esplorazione delle Feature
  - 3.4 Sintesi della Feature Engineering
  - 3.5 Creazione della Tabella Finale

- 4. Modellazione Predittiva
  - 4.1 Approccio Multiclasse
  - 4.2 Classificazione Binaria
    - 4.2.1 Preparazione dei Dati
    - 4.2.2 Risultati della Modellazione
    - 4.2.3 Confronto dei Modelli
    - 4.2.4 Analisi dell'Importanza delle Feature
    - 4.2.5 Dimostrazione del Modello
- 5. Clustering e Segmentazione della Popolazione
  - 5.1 Scelta del Numero di Cluster
  - 5.2 Analisi dei Cluster
  - 5.3 Profili dei Cluster e Interpretazione
- 6. Contesto Latam e Confronti
  - 6.1 Indicatori Chiave
  - 6.2 Confronto USA vs Latam
  - 6.3 Implicazioni
- 7. Conclusioni e Raccomandazioni
  - 7.1 Sintesi del Progetto
  - 7.2 Risultati Principali
  - 7.3 Raccomandazioni
  - 7.4 Limitazioni e Lavori Futuri
- 8. Dashboard Streamlit
  - 8.1 Dashboard Interattiva Live
  - 8.2 Screenshot

1. Preparazione e Pulizia dei Dati

1.1. Preparazione dei Dati

```
Table 'cdc' loaded.
Table 'idf' loaded.
Table 'paho_prevalence' loaded.
Table 'paho_burden' loaded.
Table 'paho_deaths_country' loaded.
Table 'paho_summary' loaded.

=== CDC ===
Rows: 261,589

Columns:
             column_name column_type
0           Diabetes_012      DOUBLE
1          KidneyDisease      DOUBLE
2                 HighBP      DOUBLE
3               HighChol      DOUBLE
4              CholCheck      DOUBLE
5                 Asthma      DOUBLE
6                   COPD      DOUBLE
7                    BMI      DOUBLE
8                 Smoker      DOUBLE
9                 Stroke      DOUBLE
10  HeartDiseaseorAttack      DOUBLE
11          PhysActivity      DOUBLE
12     HvyAlcoholConsump      DOUBLE
13         AnyHealthcare      DOUBLE
14           NoDocbcCost      DOUBLE
15               GenHlth      DOUBLE
16              MentHlth      DOUBLE
17              PhysHlth      DOUBLE
18              DiffWalk      DOUBLE
19                   Sex      DOUBLE
20              AgeGroup      DOUBLE
21             Education      DOUBLE
22                Income      DOUBLE

First 3 rows:
   Diabetes_012  KidneyDisease  HighBP  HighChol  CholCheck  Asthma  COPD  \
0           0.0            2.0     1.0       1.0        1.0     1.0   2.0
1           2.0            2.0     1.0       0.0        1.0     2.0   2.0
2           0.0            2.0     1.0       1.0        1.0     2.0   2.0

    BMI  Smoker  Stroke  HeartDiseaseorAttack  PhysActivity  \
0  22.0     1.0     0.0                   0.0           1.0
1  26.0     0.0     0.0                   0.0           1.0
2  30.0     0.0     0.0                   0.0           1.0

   HvyAlcoholConsump  AnyHealthcare  NoDocbcCost  GenHlth  MentHlth  PhysHlth  \
0                0.0            1.0          1.0      4.0       2.0       6.0
1                0.0            1.0          0.0      4.0       0.0       0.0
2                0.0            1.0          0.0      3.0       3.0       2.0

   DiffWalk  Sex  AgeGroup  Education  Income
0       1.0  0.0      13.0        4.0     2.0
1       1.0  0.0      12.0        5.0     7.0
2       0.0  0.0       9.0        5.0     7.0

=== IDF ===
Rows: 88
```

```
Columns:
  column_name column_type
0    Category     VARCHAR
1      Metric     VARCHAR
2        Year      BIGINT
3       Value      DOUBLE

First 3 rows:
                       Category  \
0  Diabetes estimates (20-79 y)
1  Diabetes estimates (20-79 y)
2  Diabetes estimates (20-79 y)

                                                Metric  Year   Value
0                     People with diabetes, in 1,000s  2000  8553.3
1         Age-standardised prevalence of diabetes, %  2000     3.7
2  Proportion of people with undiagnosed diabetes, %  2000     NaN

=== PAHO_PREVALENCE ===
Rows: 180

Columns:
         column_name column_type
0      Location Code     VARCHAR
1   Location Name En     VARCHAR
2  Indicator Name En     VARCHAR
3       Age Group En     VARCHAR
4             Sex En     VARCHAR
5               Year      BIGINT
6              Value     VARCHAR
7          Value Low     VARCHAR
8         Value High     VARCHAR

First 3 rows:
  Location Code        Location Name En  \
0           AMR  Region of the Americas
1           AMR  Region of the Americas
2           AMR  Region of the Americas

                                   Indicator Name En Age Group En      Sex En  \
0  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes
1  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes
2  Diabetes treatment coverage (current use of gl...    30+ years  Both sexes

   Year   Value Value Low Value High
0  1990  42.47%    38.20%     46.90%
1  1995  44.62%    41.00%     48.20%
2  2000  46.60%    43.80%     49.50%

=== PAHO_BURDEN ===
Rows: 120

Columns:
        column_name column_type
0              Iso3     VARCHAR
1     Location Name     VARCHAR
2   AMRO subregions     VARCHAR
3     Causename Eng     VARCHAR
4              Year      BIGINT
5               Sex     VARCHAR
```

```
6         Age group     VARCHAR
7   Measure Name En     VARCHAR
8    Metric Name En     VARCHAR
9             Value     VARCHAR
10        Value Low     VARCHAR
11         Value Up     VARCHAR

First 3 rows:
   Iso3           Location Name         AMRO subregions  \
0  AMRO  Region of the Americas  Region of the Americas
1  AMRO  Region of the Americas  Region of the Americas
2  AMRO  Region of the Americas  Region of the Americas

                                       Causename Eng  Year         Sex  \
0  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes
1  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes
2  Diabetes mellitus (excluding CKD due to Diabetes)  2019  Both sexes

          Age group                         Measure Name En Metric Name En  \
0  Age-standardized                                  Deaths           Rate
1  Age-standardized  Disability-Adjusted Life Years (DALYs)           Rate
2  Age-standardized      Years Lived with Disability (YLDs)           Rate

      Value Value Low  Value Up
0     19.64     17.26     22.02
1  1,119.49    866.64  1,423.70
2    604.86     408.1    847.76

=== PAHO_DEATHS_COUNTRY ===
Rows: 35

Columns:
              column_name column_type
0                    Iso3     VARCHAR
1       Quintiles classes     VARCHAR
2           Causename Eng     VARCHAR
3           Location Name     VARCHAR
4         Measure Name En     VARCHAR
5                    Year      BIGINT
6    Latitude (generated)      DOUBLE
7   Longitude (generated)      DOUBLE
8               Value Low      DOUBLE
9                Value Up      DOUBLE
10                  Value      DOUBLE

First 3 rows:
  Iso3      Quintiles classes  \
0  VEN  Quintile 3: 40 to 60%
1  VCT  Quintile 3: 40 to 60%
2  USA  Quintile 1:  0 to 20%

                                       Causename Eng  \
0  Diabetes mellitus (excluding CKD due to Diabetes)
1  Diabetes mellitus (excluding CKD due to Diabetes)
2  Diabetes mellitus (excluding CKD due to Diabetes)

                       Location Name Measure Name En  Year  \
0  Venezuela, Bolivarian Republic of          Deaths  2019
1   Saint Vincent and the Grenadines          Deaths  2019
2           United States of America          Deaths  2019
```

```
   Latitude (generated)  Longitude (generated)  Value Low   Value Up  \
0                6.9830               -64.5880   30.33924  49.751212
1               13.2528               -61.1949   35.87554  50.156859
2               40.0792               -98.8164    8.34613   9.646632

       Value
0  39.291483
1  42.725138
2   9.115689

=== PAHO_SUMMARY ===
Rows: 66

Columns:
          column_name column_type
0  Year of Year dated      BIGINT
1   Indicator Name En     VARCHAR
2    % of Total Value     VARCHAR

First 3 rows:
   Year of Year dated                                  Indicator Name En  \
0                1990  Number of people aged 30+ years with diabetes ...
1                1991  Number of people aged 30+ years with diabetes ...
2                1992  Number of people aged 30+ years with diabetes ...

  % of Total Value
0        42.36717%
1        42.77484%
2        43.18176%

Diabetes_012 (CDC): Distribution
   Diabetes_012   count  percentage
0           0.0  216762       82.86
1           1.0    6581        2.52
2           2.0   38246       14.62
```

1.2. Pulizia Iniziale dei Dati

Eseguirò:

- Convertire stringhe percentuali in valori float
- Controllare valori mancanti
- Standardizzare i nomi delle colonne (minuscolo, senza spazi)
- Creare versioni pulite delle tabelle se necessario

```
Example after cleaning (PAHO Prevalence):
                                   Indicator Name En  Year  Value Value Low  \
0  Diabetes treatment coverage (current use of gl...  2019  56.28      53.2
1  Diabetes treatment coverage (current use of gl...  2022  57.71      53.3
2  Diabetes treatment coverage (current use of gl...  2019  56.72      52.2
3  Diabetes treatment coverage (current use of gl...  2022  57.83      51.5
4  Diabetes treatment coverage (current use of gl...  2019  55.89      51.2
5  Diabetes treatment coverage (current use of gl...  2022  57.65      50.9
6  Diabetes treatment coverage (current use of gl...  2019  57.57      54.4
7  Diabetes treatment coverage (current use of gl...  2022   59.3      54.9
8  Diabetes treatment coverage (current use of gl...  2019  58.13      53.6
9  Diabetes treatment coverage (current use of gl...  2022  59.51      53.1

  Value High
0       59.4
1       62.1
2       61.0
3       63.9
4       60.3
5       63.9
6       60.7
7       63.7
8       62.5
9       65.6

Missing values in CDC:
             column_name  missing_count
0                 HighBP            0.0
1   HeartDiseaseorAttack            0.0
2      HvyAlcoholConsump            0.0
3           Diabetes_012            0.0
4                 Income            0.0
5          AnyHealthcare            0.0
6                 Asthma            0.0
7                 Stroke            0.0
8               PhysHlth            0.0
9                    Sex            0.0
10             Education            0.0
11         KidneyDisease            0.0
12                   BMI            0.0
13               GenHlth            0.0
14              HighChol            0.0
15             CholCheck            0.0
16                  COPD            0.0
17              MentHlth            0.0
18           NoDocbcCost            0.0
19              DiffWalk            0.0
20          PhysActivity            0.0
21                Smoker            0.0
22              AgeGroup            0.0

All looks clean and ready for EDA.
```

1.3. Pulizia Finale dei Dati e Standardizzazione

Qui standardizzo i nomi delle colonne (minuscolo, underscore) in tutte le tabelle e converto la colonna percentuale rimanente nel riepilogo PAHO.

```
Example after cleaning PAHO Summary:
   Year of Year dated                                Indicator Name En  \
0                2019  Number of people aged 30+ years with diabetes ...
1                2022  Number of people aged 30+ years with diabetes ...
2                2019  Number of people aged 30+ years with diabetes ...
3                2022  Number of people aged 30+ years with diabetes ...

  % of Total Value
0         57.56768
1         59.30143
2         42.43232
3         40.69857

Standardized columns in cdc
Standardized columns in idf
Standardized columns in paho_prevalence
Standardized columns in paho_burden
Standardized columns in paho_deaths_country
Standardized columns in paho_summary

CDC columns after standardization:
             column_name
0           diabetes_012
1          kidneydisease
2                 highbp
3               highchol
4              cholcheck
5                 asthma
6                   copd
7                    bmi
8                 smoker
9                 stroke
10  heartdiseaseorattack
11          physactivity
12     hvyalcoholconsump
13         anyhealthcare
14           nodocbccost
15               genhlth
16              menthlth
17              physhlth
18              diffwalk
19                   sex
20              agegroup
21             education
22                income

All tables are now clean and standardized. Ready for EDA!
```

1.4. Conversione Finale a Tipo Numerico

Qui convertirò tutte le colonne che devono essere numeriche da VARCHAR a DOUBLE. Questo serve a evitare CAST ripetuti e garantire calcoli corretti.

```
Final numeric conversion check & fix...
  Converted paho_prevalence.value → DOUBLE
  Converted paho_prevalence.value_low → DOUBLE
  Converted paho_prevalence.value_high → DOUBLE
  Converted paho_burden.value → DOUBLE
  Converted paho_burden.value_low → DOUBLE
  Converted paho_burden.value_up → DOUBLE
  Converted paho_summary.percent_of_total_value → DOUBLE
  paho_deaths_country.value is already numeric (DOUBLE) - skipping
  paho_deaths_country.value_low is already numeric (DOUBLE) - skipping
  paho_deaths_country.value_up is already numeric (DOUBLE) - skipping

Final column types check:

PAHO_PREVALENCE:
         column_name column_type
0      location_code     VARCHAR
1   location_name_en     VARCHAR
2  indicator_name_en     VARCHAR
3       age_group_en     VARCHAR
4             sex_en     VARCHAR
5               year      BIGINT
6              value      DOUBLE
7          value_low      DOUBLE
8         value_high      DOUBLE

PAHO_BURDEN:
        column_name column_type
0              iso3     VARCHAR
1     location_name     VARCHAR
2   amro_subregions     VARCHAR
3     causename_eng     VARCHAR
4              year      BIGINT
5               sex     VARCHAR
6         age_group     VARCHAR
7   measure_name_en     VARCHAR
8    metric_name_en     VARCHAR
9             value      DOUBLE
10        value_low      DOUBLE
11         value_up      DOUBLE

PAHO_SUMMARY:
              column_name column_type
0      year_of_year_dated      BIGINT
1       indicator_name_en     VARCHAR
2  percent_of_total_value      DOUBLE

PAHO_DEATHS_COUNTRY:
            column_name column_type
0                  iso3     VARCHAR
1     quintiles_classes     VARCHAR
2         causename_eng     VARCHAR
3         location_name     VARCHAR
4       measure_name_en     VARCHAR
5                  year      BIGINT
6    latitude_generated      DOUBLE
7   longitude_generated      DOUBLE
8             value_low      DOUBLE
9              value_up      DOUBLE
10                value      DOUBLE
```

2. Analisi Esplorativa dei Dati (EDA)

Esplorerò:

- Distribuzione della variabile target ('Diabetes_012')
- Principali fattori demografici e di rischio sanitario
- Relazioni tra variabili e stato di diabete
- Contesto iniziale dell'America Latina (tendenze di prevalenza)

2.1. Analisi Visiva

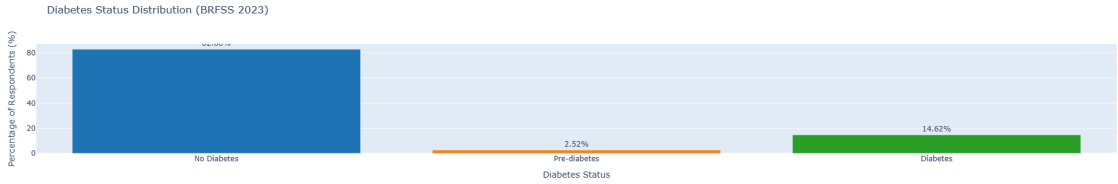

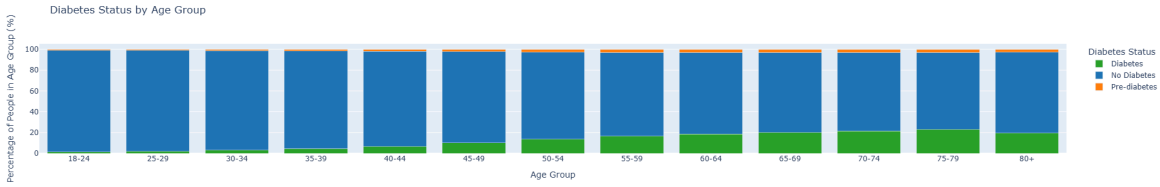

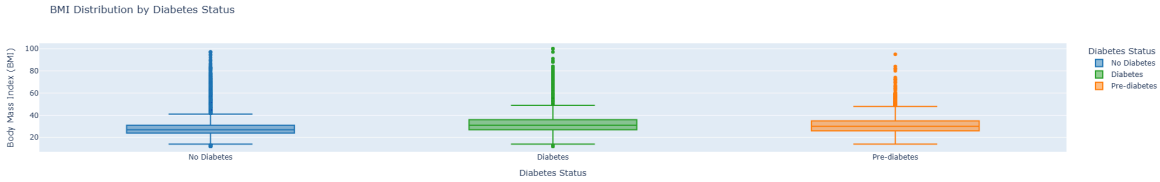


```
Diabetes Prevalence Trend (Americas 18+ years, age-standardized):
   year  avg_prevalence_percent
0  1990                    7.06
1  1995                    7.83
2  2000                    8.51
3  2005                    9.41
4  2010                   10.57
5  2015                   11.53
6  2019                   12.32
7  2020                   12.55
8  2021                   12.80
9  2022                   13.06
```

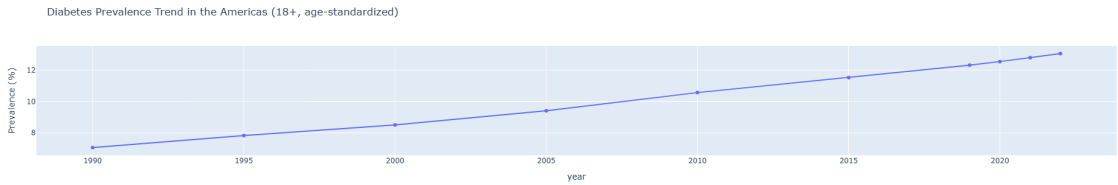

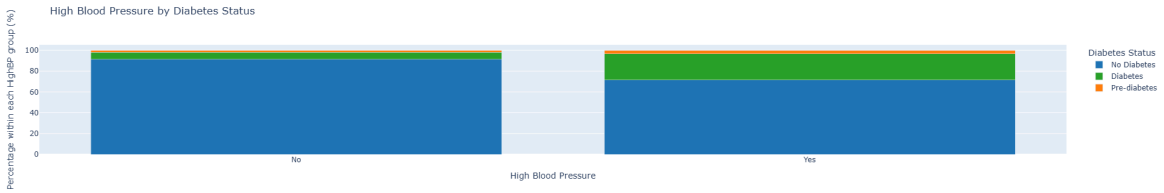

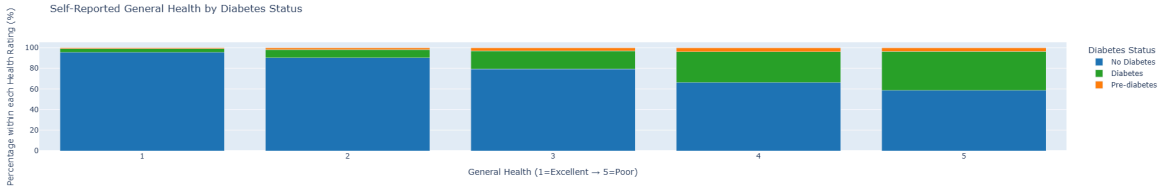

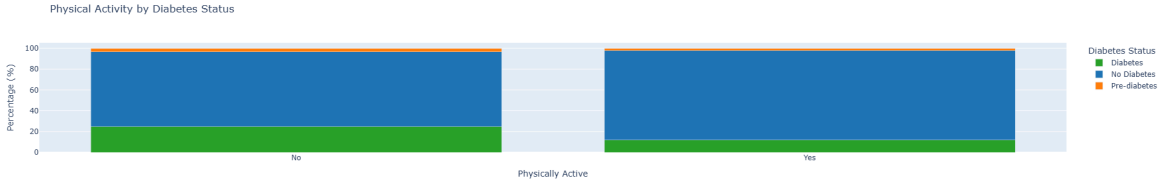

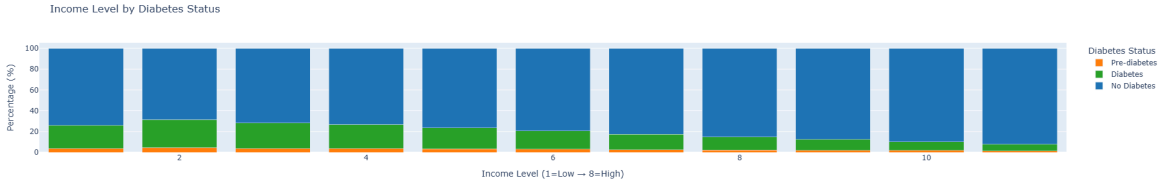

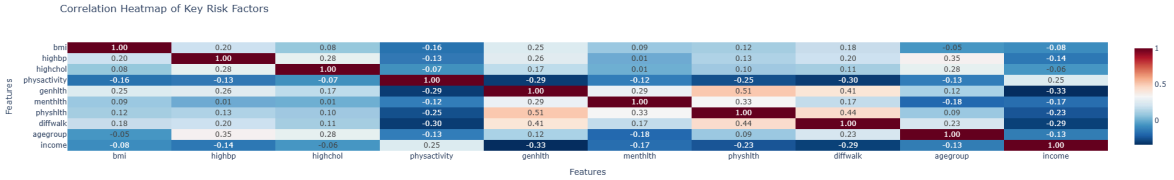

2.2. Principali Insights e Conclusioni

1. Distribuzione della Variabile Target

- Il dataset è fortemente sbilanciato: **82.86%** degli intervistati non hanno diabete, **14.62%** hanno diabete e solo **2.52%** sono nella categoria pre-diabete.
- Questo sbilanciamento è tipico nei dati sanitari reali e dovrà essere gestito con attenzione durante la modellazione (es. usando pesi di classe o SMOTE).

2. Fattori di Rischio Più Forti

- **BMI**: Gli individui con diabete (classe 2) mostrano una mediana di BMI significativamente più alta. L'obesità appare come uno dei fattori più associati.
- **Ipertensione**: Le persone con HighBP hanno una proporzione molto più alta di casi di diabete. La relazione è chiarissima nel grafico a barre impilate.
- **Salute Generale**: Esiste un forte gradiente: più è peggiore la salute generale auto-riferita (punteggio GenHlth più alto), maggiore è la percentuale di diabete.

- **Età**: La prevalenza del diabete aumenta notevolmente con l'età, soprattutto dopo i 50–55 anni.
- **Attività Fisica**: Gli intervistati che dichiarano di essere fisicamente attivi mostrano una proporzione inferiore di diabete.

3. Pattern Socioeconomici

- Livelli di reddito più bassi sono associati a maggiore prevalenza di diabete, suggerendo possibili legami con accesso alla sanità, nutrizione e risorse di prevenzione.

4. Contesto dell'America Latina

- La prevalenza del diabete nelle Americhe (standardizzata per età, 18+) è aumentata da ~7.1% nel 1990 a ~13.1% nel 2022.
- Le proiezioni IDF per Sud e Centro America mostrano un aumento preoccupante: da 10.1% nel 2024 a una stima di **11.5% nel 2050**, con un gran numero di casi non diagnosticati (~30.4% nel 2024).
- Il carico della malattia (DALYs, morti) è particolarmente elevato in sottoregioni come Centro America e Caraibi non latini.

5. Principali Conclusioni per la Sanità Pubblica

- Gli sforzi di prevenzione dovrebbero concentrarsi su **fattori di rischio modificabili**: controllo del BMI, gestione della pressione arteriosa e promozione dell'attività fisica.
- Interventi mirati a **anziani (55+)** e **gruppi a basso reddito** potrebbero avere grande impatto.
- La tendenza crescente in America Latina evidenzia l'urgenza di politiche di prevenzione, screening precoce e miglioramento della copertura del trattamento (attualmente ~57–59% nella regione).

Questi insights guideranno le mie prossime fasi di feature engineering, modellazione e clustering, così come le raccomandazioni finali per strategie di sanità pubblica in Argentina e America Latina.

---

3. Feature Engineering e SQL Avanzato

In questa sezione userò DuckDB per creare nuove variabili significative ed eseguire trasformazioni complesse.

Questo dimostrerà una preparazione dei dati efficiente su larga scala e conoscenza del dominio nei fattori di rischio del diabete.

Obiettivi principali:

- Creare variabili clinicamente rilevanti (gruppi di età, categorie di BMI, punteggi di comorbidità, ecc.)
- Ingegnerizzare caratteristiche di interazione e rischio
- Arricchire il dataset principale con contesto Latam tramite join
- Preparare un set di feature pulito per modellazione e clustering

3.1. Creazione di una Tabella di Lavoro

```
Creating clean working table 'diabetes_features' for engineering...
Working table 'diabetes_features' created with 261589 rows
```

3.2. Feature Engineering

```
Starting feature engineering...
Feature engineering completed. New features added.

Sample of engineered features:
   diabetes_012        age_group_cat     bmi_category  comorbidity_count  \
0           0.0        Elderly (75+)           Normal                  7
1           2.0        Elderly (75+)       Overweight                  7
2           0.0       Senior (60-74)    Obese Class I                  8
3           0.0        Elderly (75+)    Obese Class I                  7
4           2.0        Elderly (75+)           Normal                  9
5           0.0  Middle Aged (45-59)  Obese Class III                  8
6           0.0       Senior (60-74)    Obese Class I                  6
7           0.0        Elderly (75+)           Normal                  6

   diabetes_risk_score                 age_bmi_risk_group  lifestyle_score
0                    4                      Standard Risk                2
1                    3                      Standard Risk                3
2                    3          High Risk: Senior + Obese                3
3                    5          High Risk: Senior + Obese                2
4                    2                      Standard Risk                2
5                    3  Moderate Risk: Middle-age + Obese                3
6                    2          High Risk: Senior + Obese                2
7                    1                      Standard Risk                1
```

3.3. Esplorazione delle Feature

Qui analizzerò come le nuove feature create si relazionano con lo stato di diabete.

```
=== Feature Exploration: New Variables vs Diabetes Status ===

1. Age Group Category vs Diabetes Prevalence:
         age_group_cat  total_count  diabetes_cases  diabetes_pct
0        Elderly (75+)        42191          8990.0         21.31
1       Senior (60-74)        88039         17700.0         20.10
2  Middle Aged (45-59)        64257          8824.0         13.73
3  Young Adult (18-44)        67102          2732.0          4.07

2. BMI Category vs Diabetes Prevalence:
      bmi_category  total_count  diabetes_cases  diabetes_pct
0      Underweight         3495           208.0          5.95
1           Normal        64682          4464.0          6.90
2       Overweight        93432         11392.0         12.19
3    Obese Class I        58433         11045.0         18.90
4   Obese Class II        24696          6079.0         24.62
5  Obese Class III        16851          5058.0         30.02

3. Average Comorbidities and Risk Score by Diabetes Status:
   diabetes_012  avg_comorbidities  avg_risk_score  avg_lifestyle_score
0           0.0               6.64            1.54                 2.35
1           1.0               7.08            2.53                 2.22
2           2.0               7.28            3.06                 2.13

4. Age + BMI Risk Groups vs Diabetes Prevalence:
                  age_bmi_risk_group  total_count  diabetes_pct
0          High Risk: Senior + Obese        46214         30.81
1  Moderate Risk: Middle-age + Obese        20456         23.27
2                      Standard Risk       194919          9.88
```

3.4. Sintesi della Feature Engineering

Principali feature create e loro relazione con il diabete:

- **Gruppo di Età**: Forte correlazione positiva con l'età. Gli anziani (75+) mostrano una prevalenza di diabete del 21.31%.
- **Categoria BMI**: Predittore molto forte. L'Obesità Classe III ha un tasso di diabete del 30.02% vs 6.90% nel peso normale.
- **Gruppo di Rischio Età + BMI**: Il gruppo a rischio più alto ("Alto Rischio: Senior + Obeso") ha una prevalenza di diabete del 30.81%.
- **Conteggio Comorbidità** e **Punteggio di Rischio Diabete**: Entrambi aumentano con lo stato di diabete.
- **Punteggio Stile di Vita**: Leggermente più basso nelle persone con diabete.

Queste feature catturano dimensioni cliniche e comportamentali importanti e saranno utilizzate per modellazione e clustering.

3.5. Creazione della Tabella Finale per la Modellazione

Qui creo una tabella finale pulita `diabetes_model_ready` contenente sia feature originali che ingegnerizzate, pronta per modellazione e clustering.

```
Creating final modeling table...
Final modeling table 'diabetes_model_ready' created with 261589 rows

Columns ready for modeling:
['target', 'bmi', 'highbp', 'highchol', 'physactivity', 'genhlth', 'diffwalk', 'a
gegroup', 'income', 'sex', 'age_group_cat', 'bmi_category', 'comorbidity_count',
'diabetes_risk_score', 'age_bmi_risk_group', 'lifestyle_score', 'obese_class_ii
i', 'senior_or_elderly', 'has_metabolic_risk']
```

---

4. Modellazione Predittiva

Costruirò modelli di classificazione per prevedere il rischio di diabete utilizzando le feature ingegnerizzate nella sezione precedente.

Obiettivi

- Stabilire un modello di base solido
- Valutare le prestazioni usando metriche appropriate per dati sanitari sbilanciati
- Identificare le feature più importanti
- Confrontare diversi algoritmi (Regressione Logistica vs Random Forest)

Utilizzerò la tabella `diabetes_model_ready` creata nella sezione precedente.

4.1. Approccio Multiclasse (Tentativo Iniziale)

Ho inizialmente provato a prevedere tre classi separate:

- 0 = Nessun Diabete
- 1 = Pre-diabete
- 2 = Diabete

I modelli **hanno avuto prestazioni scarse**, soprattutto sulla classe minoritaria (pre-diabete), principalmente a causa del forte sbilanciamento delle classi (82.86% Nessun Diabete, 2.52% Pre-diabete, 14.62% Diabete).

Dopo aver rivisto i risultati, ho deciso di semplificare il problema.

```
=== Preparing Data for Modeling ===

Shape after One-Hot Encoding: (261589, 26)
Categorical columns encoded: ['age_group_cat', 'bmi_category', 'age_bmi_risk_grou
p']
Training samples: 209,271
Test samples: 52,318
Class distribution in training set:
target
0.0    82.86
2.0    14.62
1.0     2.52
Name: proportion, dtype: float64
```

```
=== Training Multiple Models ===

Training Logistic Regression...

Logistic Regression Classification Report:
              precision    recall  f1-score   support

         0.0     0.9421    0.6324    0.7568     43353
         1.0     0.0386    0.2682    0.0674      1316
         2.0     0.3354    0.6168    0.4345      7649

    accuracy                         0.6210     52318
   macro avg     0.4387    0.5058    0.4196     52318
weighted avg     0.8307    0.6210    0.6923     52318

F1-score for Diabetes class (2): 0.4345
------------------------------------------------------------
Training Random Forest...

Random Forest Classification Report:
              precision    recall  f1-score   support

         0.0     0.8552    0.8912    0.8728     43353
         1.0     0.0255    0.0236    0.0245      1316
         2.0     0.3361    0.2603    0.2934      7649

    accuracy                         0.7771     52318
   macro avg     0.4056    0.3917    0.3969     52318
weighted avg     0.7584    0.7771    0.7668     52318

F1-score for Diabetes class (2): 0.2934
------------------------------------------------------------
Training XGBoost...

XGBoost Classification Report:
              precision    recall  f1-score   support

         0.0     0.8488    0.9783    0.9090     43353
         1.0     0.0000    0.0000    0.0000      1316
         2.0     0.5544    0.1700    0.2602      7649

    accuracy                         0.8355     52318
   macro avg     0.4677    0.3828    0.3897     52318
weighted avg     0.7844    0.8355    0.7912     52318

F1-score for Diabetes class (2): 0.2602
------------------------------------------------------------
```

4.2. Classificazione Binaria (Approccio Finale)

Dato il forte sbilanciamento e il limitato potere predittivo sul pre-diabete, ho semplificato il problema a **classificazione binaria**:

- **Classe 0**: Nessun Diabete
- **Classe 1**: Pre-diabete **o** Diabete (qualsiasi rischio di diabete)

Questo approccio è più pratico per lo screening reale e ha prodotto risultati significativamente migliori.

4.2.1. Preparazione dei Dati per la Classificazione Binaria

Ho creato la variabile target binaria e applicato One-Hot Encoding alle variabili categoriche (`age_group_cat` , `bmi_category` , `age_bmi_risk_group`).

```
=== Binary Classification: No Diabetes vs Any Diabetes Risk ===

Training samples: 209,271
Test samples: 52,318
Positive class (Any diabetes risk) percentage: 17.14%
```

4.2.2. Risultati della Modellazione

Regressione Logistica

```
Training Logistic Regression (Binary)...
Logistic Regression Results:
              precision    recall  f1-score   support

           0     0.9329    0.7014    0.8007     43353
           1     0.3436    0.7561    0.4725      8965

    accuracy                         0.7107     52318
   macro avg     0.6383    0.7287    0.6366     52318
weighted avg     0.8319    0.7107    0.7445     52318
```

Random Forest

```
Training Random Forest (Binary)...
Random Forest Results:
              precision    recall  f1-score   support

           0     0.8591    0.8956    0.8770     43353
           1     0.3646    0.2898    0.3229      8965

    accuracy                         0.7918     52318
   macro avg     0.6119    0.5927    0.6000     52318
weighted avg     0.7744    0.7918    0.7820     52318
```

XGBoost

```
Training XGBoost (Binary)...
XGBoost Results:
              precision    recall  f1-score   support

           0     0.8517    0.9716    0.9077     43353
           1     0.5694    0.1816    0.2754      8965

    accuracy                         0.8362     52318
   macro avg     0.7105    0.5766    0.5915     52318
weighted avg     0.8033    0.8362    0.7993     52318
```

4.2.3. Confronto dei Modelli

Confronto dei modelli e insights:

- **Regressione Logistica** ha ottenuto il miglior **recall** (75.61%) per la classe positiva (qualsiasi rischio di diabete). Significa che è buona nell'identificare persone a rischio, anche se a volte genera falsi allarmi.
- **XGBoost** ha avuto la massima accuratezza complessiva (83.62%) e la migliore precisione, ma ha mancato molti casi reali (recall basso).
- **Random Forest** si è posizionato nel mezzo ma non è stato il migliore in nessuna metrica chiave.

Modello scelto: Regressione Logistica — perché nello screening di sanità pubblica è più importante individuare il maggior numero possibile di persone a rischio (alto recall) che essere molto precisi.

Questi risultati mostrano che le feature ingegnerizzate (soprattutto BMI, età, reddito e conteggio comorbidità) contengono segnale predittivo utile per il rischio di diabete.

4.2.4. Analisi dell'Importanza delle Feature

Capire quali feature contribuiscono maggiormente alla predizione è cruciale per l'interpretabilità e le raccomandazioni di sanità pubblica.

```
Top 15 Most Important Features (XGBoost):
                              feature  importance
10                diabetes_risk_score    0.368261
17  age_group_cat_Young Adult (18-44)    0.081003
13                  senior_or_elderly    0.068727
4                             genhlth    0.053791
24   age_bmi_risk_group_Standard Risk    0.049790
6                            agegroup    0.037466
14                 has_metabolic_risk    0.036997
20       bmi_category_Obese Class III    0.032434
1                              highbp    0.030059
3                        physactivity    0.022631
8                                 sex    0.021122
12                    obese_class_iii    0.021052
18         bmi_category_Obese Class I    0.018625
11                    lifestyle_score    0.016660
0                                 bmi    0.016236
```

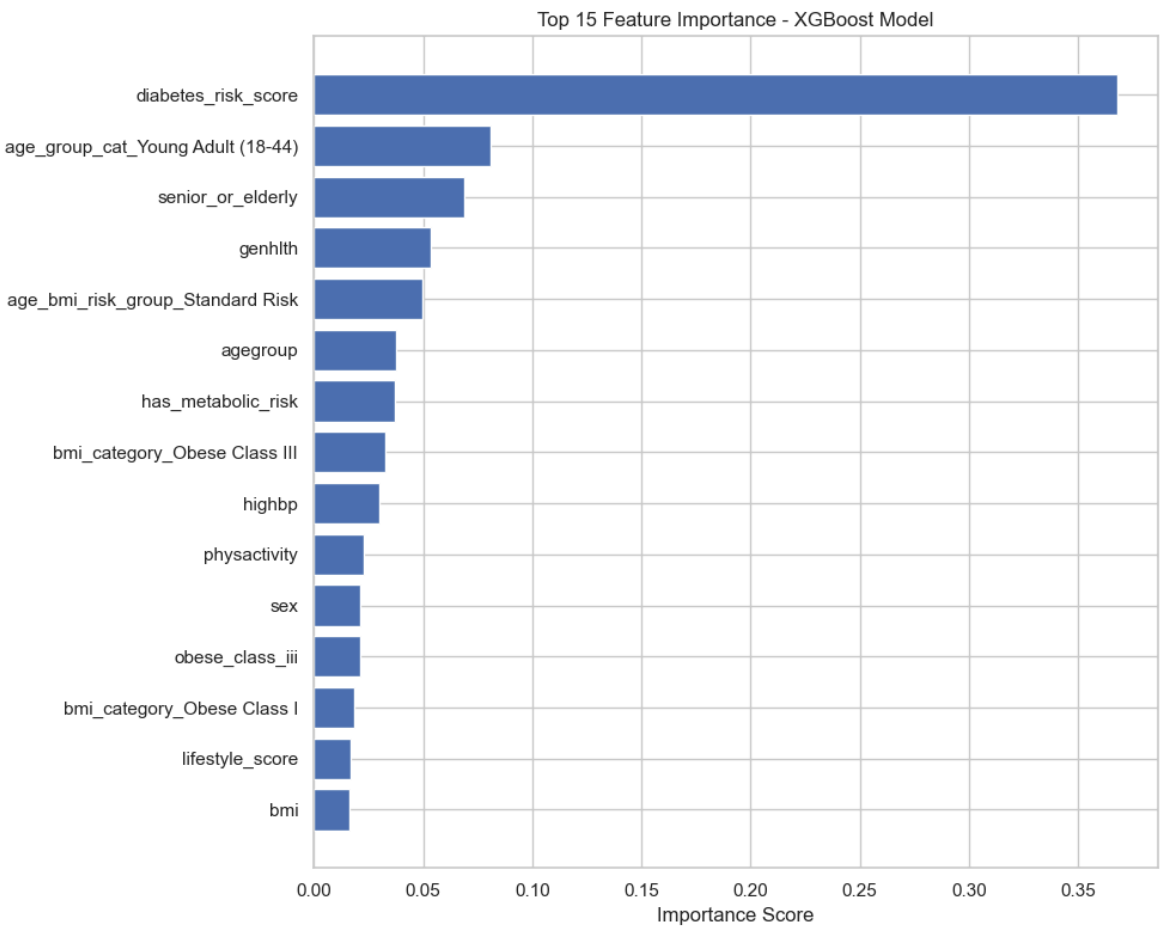

Top 5 feature più importanti:

1. diabetes_risk_score (0.368) — Il mio punteggio composito ingegnerizzato è il predittore più forte
2. Essere Giovane Adulto (fattore protettivo)
3. senior_or_elderly (età 60+)
4. genhlth (salute generale auto-riferita)
5. age_bmi_risk_group_Standard Risk

Questo conferma che la feature engineering ha aggiunto valore significativo al modello.

Applicazione Pratica

Questo modello può essere utilizzato come Strumento di Screening del Rischio Diabete:

- I medici possono inserire i dati dei pazienti per stimare il livello di rischio.
- Le organizzazioni di sanità pubblica potrebbero usarlo per prioritizzare campagne di screening nei gruppi ad alto rischio (anziani, persone obese, popolazioni a basso reddito).
- Una versione web/app semplificata permetterebbe agli individui di fare un rapido auto-check.

Esempio di Utilizzo:

Un paziente di 62 anni con BMI 32, ipertensione e cattiva salute auto-riferita verrebbe segnalato come ad alto rischio, spingendo a test glicemici precoci e interventi sullo stile

di vita.

4.2.5. Dimostrazione del Modello con Pazienti Esempio

Per illustrare come il modello potrebbe essere usato nella pratica, l'ho testato su cinque profili realistici di pazienti.

```
=== Model Demonstration with Example Patients ===

Using Logistic Regression (best recall model)

      age_group_cat  bmi_category  genhlth  highbp  physactivity Predicted Risk
Risk Probability (%)
Young Adult (18-44)        Normal        2       0             1       Low Risk
4.9
Young Adult (18-44)    Overweight        3       0             0       Low Risk
12.6
Middle Aged (45-59)    Overweight        3       1             1      High Risk
63.6
     Senior (60-74) Obese Class I        4       1             0      High Risk
87.1
     Senior (60-74) Obese Class I        4       1             0      High Risk
86.7
```

Interpretazione:

Il modello si comporta logicamente nella maggior parte dei casi. Gli anziani con obesità e cattiva salute generale sono classificati correttamente come ad alto rischio (86–87% di probabilità). Una persona di mezza età con sovrappeso e ipertensione è anch'essa segnalata come ad alto rischio.

Tuttavia, il modello rimane relativamente conservativo con i giovani adulti — anche un giovane adulto sovrappeso con bassa attività fisica riceve solo un rischio del 12.6%. Ciò suggerisce che l'età è un fattore molto forte nel modello attuale. In un deployment reale, questo potrebbe essere regolato a seconda che si preferisca maggiore sensibilità (individuare più casi) o maggiore specificità.

---

5. Clustering e Segmentazione della Popolazione

Applicherò apprendimento non supervisionato (K-Means) per segmentare gli individui in distinti gruppi di rischio basati sulle loro caratteristiche.

Questo consente di identificare sottogruppi omogenei e fornire raccomandazioni di sanità pubblica più mirate.

5.1. Scelta del Numero di Cluster

Di seguito utilizzo il Metodo del Gomito per determinare il numero ottimale di cluster. Il grafico dell'inerzia ha mostrato una curva ragionevole intorno a 4 cluster, che ho adottato per interpretabilità.

```
=== Clustering Analysis ===
```

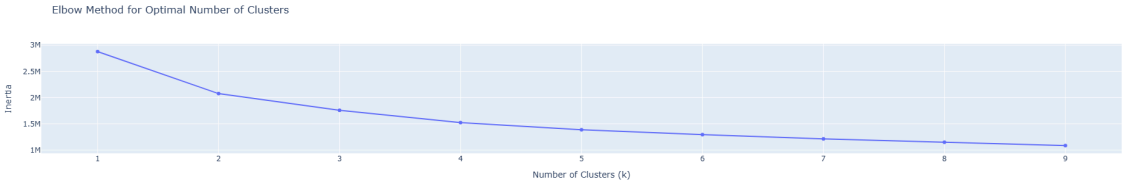


```
Cluster distribution:
cluster
0    95187
1    66017
2    37846
3    62539
Name: count, dtype: int64

Cluster Profiles (mean values):
           bmi  agegroup  genhlth  highbp  comorbidity_count  \
cluster
0        28.19      4.89     2.26    0.15               6.18
1        30.33      9.72     2.97    1.00               7.97
2        30.88      8.37     3.10    0.35               6.39
3        26.96     10.67     2.33    0.31               6.51

         diabetes_risk_score  lifestyle_score  target
cluster
0                       0.81             2.61    0.10
1                       3.33             2.16    0.64
2                       2.73             1.46    0.39
3                       1.08             2.55    0.26
```

5.2. Analisi dei Cluster

Come si vede sopra, ho ottenuto i seguenti quattro cluster:

Distribuzione dei Cluster:

- Cluster 0: 95,187 persone (36.4%)
- Cluster 1: 66,017 persone (25.2%)
- Cluster 2: 37,846 persone (14.5%)
- Cluster 3: 62,539 persone (23.9%)

5.3. Profili dei Cluster e Interpretazione

Ho identificato **4 segmenti di popolazione distinti** basati sulle loro caratteristiche di salute.

Cluster	Numero di Persone	Caratteristiche Principali	Prevalenza Diabete (%)	Livello di Rischio	Raccomandazione
0	95,187	Giovani adulti, peso normale, buona salute generale, poche comorbidità	10.0%	**Basso Rischio**	Prevenzione generale
1	66,017	Anziani, alto BMI, ipertensione, multiple comorbidità	64.0%	**Rischio Molto Alto**	Screening prioritario e intervento intensivo
2	37,846	Mezza età fino ad anziani, obesi, cattiva salute auto-riferita	39.0%	**Alto Rischio**	Programmi mirati sullo stile di vita
3	62,539	Anziani, BMI moderato, alcune comorbidità	26.0%	**Rischio Moderato**	Educazione preventiva e monitoraggio regolare

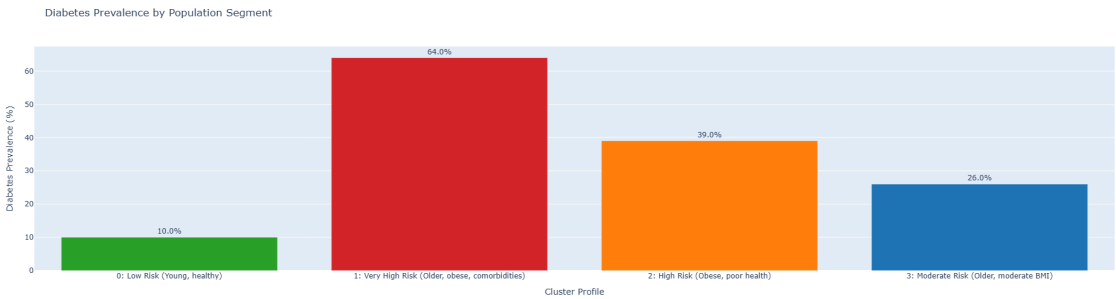

Insights Chiave:

- **Cluster 1** è il gruppo a rischio più alto (64% prevalenza diabete). È composto principalmente da anziani con obesità, ipertensione e multiple comorbidità. Questo gruppo dovrebbe essere prioritizzato per screening aggressivo e intervento.
- **Cluster 0** rappresenta il segmento più sano — principalmente giovani con buone abitudini di vita e basso rischio.
- **Cluster 2** mostra che l'obesità combinata con cattiva salute auto-riferita aumenta significativamente il rischio, anche in mezza età.
- Età e BMI continuano a essere fattori dominanti nella segmentazione del rischio, rafforzando i risultati delle fasi di EDA e modellazione.

Questi cluster forniscono insights concreti per la politica di sanità pubblica in Argentina e America Latina. Ad esempio, le risorse potrebbero essere concentrate sul Cluster 1 ("Anziani Obesi ad Alto Rischio") attraverso programmi comunitari di screening e interventi sullo stile di vita.

---

6. Contesto Latam e Confronti

Per rendere l'analisi più rilevante per l'Argentina e l'America Latina, ho arricchito i risultati del BRFSS USA con dati regionali della PAHO e dell'Atlante del Diabete IDF.

6.1. Indicatori Chiave Latam (Sud e Centro America)

Indicatore	Valore 2024	Proiezione 2050	Osservazione
Prevalenza standardizzata per età	10.1%	11.5%	Previsto aumento costante
Persone con diabete	35.4 milioni	51.5 milioni	+45% crescita prevista
Diabete non diagnosticato	~30.4%	-	Elevato carico nascosto
Copertura del trattamento (Americhe, 30+ anni)	~57–59%	-	Significativo gap di trattamento

Fonte: Atlante del Diabete IDF & dati PAHO

6.2. Confronto: Dati USA vs Contesto Latam

- Nel dataset BRFSS 2023 degli USA, il tasso osservato di diabete è **14.62%**.
- In Sud e Centro America, la prevalenza attuale è **10.1%** (2024), ma si prevede che raggiunga **11.5% entro il 2050**.
- Il cluster a rischio più alto (Cluster 1) mostra un tasso di diabete del **64%** — molto più alto delle medie USA e Latam. Ciò suggerisce che individui con profili simili (età avanzata + obesità + comorbidità) rappresentano un gruppo critico ad alto rischio in tutta la regione.
- La forte influenza di **BMI**, **età** e **comorbidità** nel mio modello è coerente con i fattori di rischio noti in America Latina, dove l'aumento dell'obesità è un motore principale dell'epidemia di diabete.

6.3. Implicazioni per Argentina e America Latina

La combinazione dei risultati di clustering e dei dati regionali evidenzia la necessità di **strategie di prevenzione mirate**:

- Prioritizzare screening e interventi sullo stile di vita per anziani con obesità e ipertensione (simile al Cluster 1).
- Affrontare l'elevato tasso di non diagnosticati (~30%) tramite programmi comunitari.
- Concentrarsi su fattori di rischio modificabili (controllo BMI e attività fisica), che hanno mostrato forte potere predittivo nel modello.

Questi risultati supportano lo sviluppo di politiche di sanità pubblica localizzate in Argentina, dove la prevalenza del diabete continua ad aumentare.

---

7. Conclusioni e Raccomandazioni

7.1. Sintesi del Progetto

Questo progetto ha analizzato il rischio di diabete utilizzando il dataset CDC BRFSS 2023 (~261k record) combinato con contesto Latam da PAHO e IDF.

Il lavoro è progredito attraverso:

- Preparazione approfondita dei dati e uso avanzato di SQL con DuckDB
- EDA completo con visualizzazioni interattive
- Feature engineering informata dal dominio (punteggi di rischio, gruppi età+BMI, conteggio comorbidità, ecc.)
- Modellazione predittiva (classificazione binaria)
- Segmentazione della popolazione con clustering K-Means

7.2. Risultati Principali

- **Predittori più forti**: BMI, età, salute generale e comorbidità sono emersi come i fattori più importanti.
- La prevalenza del diabete aumenta significativamente con l'età, passando da **4.07%** nei giovani adulti (18–44) a **21.31%** negli anziani (75+).
- Il BMI è emerso come uno dei predittori più forti, con prevalenza che sale da 6.9% nel peso normale a **30.0%** in Obesità Classe III.
- **Clustering** ha identificato **quattro segmenti di rischio**, con il gruppo a rischio più alto (anziani obesi con comorbidità) che mostra un tasso di diabete del **64%**.
- **Prestazioni del modello**: L'approccio binario ha ottenuto risultati ragionevoli, con Regressione Logistica che ha fornito il miglior recall (75.61%).
- **Contesto Latam**: La prevalenza crescente in Sud e Centro America (10.1% nel 2024 → 11.5% previsto nel 2050) e l'elevato tasso di non diagnosticati (~30%) rendono questi risultati altamente rilevanti.

7.3. Raccomandazioni

Per le Autorità Sanitarie (Argentina & Latam):

- Prioritizzare screening mirati per **Cluster 1** (anziani con obesità, ipertensione e multiple comorbidità).
- Implementare programmi di prevenzione precoce focalizzati su **gestione del peso** e **attività fisica**.
- Affrontare il gap di trattamento migliorando l'accesso alle cure nei gruppi a basso reddito.
- Utilizzare strumenti di stratificazione del rischio come quello sviluppato qui per ottimizzare risorse limitate.

Per gli Individui:

- Monitoraggio regolare di BMI, pressione arteriosa e salute generale per identificare precocemente il rischio.
- Cambiamenti nello stile di vita (più attività fisica e mantenimento del peso sano) hanno un impatto elevato.

7.4. Limitazioni e Lavori Futuri

- Il modello si basa su dati auto-riferiti, che possono contenere bias.
- Il pre-diabete rimane difficile da prevedere accuratamente con questo dataset.
- Miglioramenti futuri potrebbero includere valori di laboratorio (HbA1c, glicemia a digiuno), storia familiare o dati geografici più dettagliati.

Questo progetto dimostra competenze di analisi dei dati end-to-end — dalla preparazione intensiva in SQL alla modellazione e agli insights concreti di sanità pubblica.

---

8. Dashboard Streamlit

🚀 Dashboard Interattiva Live

Puoi esplorare la **versione completamente interattiva** di questo progetto qui:

🔗 **Apri Diabetes Risk Analyzer →**

Screenshot dall'App Live

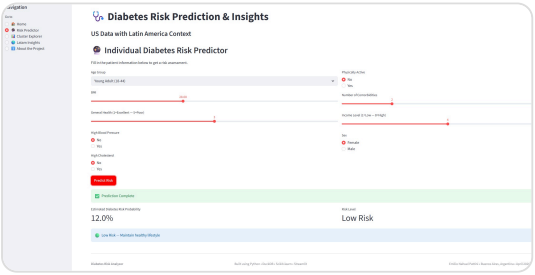

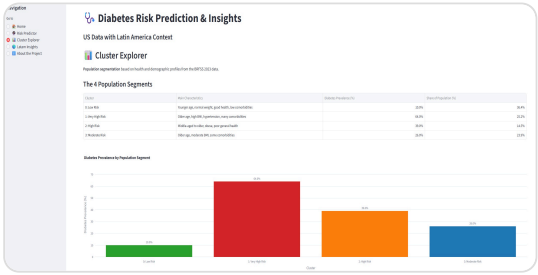

Cosa puoi fare nella dashboard live:

- Calcolare il tuo rischio personale di diabete usando il modello addestrato
- Esplorare i 4 segmenti di popolazione scoperti tramite clustering
- Visualizzare le tendenze del diabete e le proiezioni al 2050 per Sud e Centro America

Nota: La dashboard è distribuita su Streamlit Community Cloud ed è completamente interattiva.

Grazie per aver visto questo progetto!

Sentiti libero di contattarmi per domande o feedback.

```
✅ Successfully saved 'data/diabetes_model_ready.parquet'
Shape: (261589, 29)
Columns: ['diabetes_012', 'bmi', 'highbp', 'highchol', 'cholcheck', 'smoker', 'st
roke', 'heartdiseaseorattack', 'physactivity', 'hvyalcoholconsump', 'genhlth', 'm
enthlth', 'physhlth', 'diffwalk', 'sex', 'agegroup', 'education', 'income', 'kidn
eydisease', 'asthma', 'copd', 'anyhealthcare', 'nodocbccost', 'age_group_cat', 'b
mi_category', 'comorbidity_count', 'diabetes_risk_score', 'age_bmi_risk_group',
'lifestyle_score']

✅ Model saved successfully as 'models/logistic_regression_model.pkl'
Folder 'models' created if it didn't exist.

✅ Model columns saved as 'models/model_columns.json'
```